



Tối ưu hóa mô hình dự đoán tỉ lệ sống sót Titanic thông qua kĩ thuật Feature engineering lặp lại

Trần Hồ Minh Hải, Trương Văn Thiện, Phan Đức Nhân, Võ Gia Kiệt

Giới thiệu

Xác định vấn đề:

- input:** tập dữ liệu Titanic từ kaggle
- output:** dự đoán khả năng sống sót của các hành khách trên chuyến tàu Titanic gặp tai nạn


Thách thức:

- Dữ liệu thô chứa nhiều khuyết điểm
- Gồm nhiều cột ít tác động đến taget

Dataset

- 891 dữ liệu train, 418 dữ liệu test
- Nguồn dữ liệu: <https://www.kaggle.com/competitions/titanic>

Tỷ lệ Sống Sót và Tử Vong trên Tàu Titanic



Phương pháp đề xuất

Đối với các giá trị bị thiếu(missing value):



Sử dụng giá trị Median để điền khuyết
Sử dụng giá trị Mode (giá trị xuất hiện nhiều nhất)
Drop cột này do quá nhiều dữ liệu bị thiếu


Kỹ thuật Khai thác Đặc trưng (Feature Engineering - FE):

- Xử lí và mã hóa (Encoding):






- male thành 0 và female thành 1
- Áp dụng One-Hot Encoding bằng get_dummies
- Trích xuất danh xưng (Title) từ cột Name (ví dụ: Mr, Mrs, Master)
- Gom nhóm các Title ít phổ biến thành nhóm 'Other' (thường chỉ giữ lại khoảng 6 categories)
- Áp dụng get_dummies cho cột Title đã được làm sạch

- Rời rạc hóa (Categorical Binning)



- Tạo Feature Tổ hợp (Derived Features):



Kết quả và phân tích thảo luận


Đánh giá hiệu suất lặp lại:

Model	Num_Features	Validation_Acc	ROC_AUC	Final_Score
Random Forest	8	0.8212	0.8345	0.74880
Logistic Regression	14	0.8436	0.8701	0.76794
Logistic Regression	18	0.8436	0.8791	0.77751
Logistic Regression	52	0.8492	0.8757	0.77990
Logistic Regression	24	0.8380	0.9060	0.79904
Logistic Regression	23	0.8380	0.9072	0.80143

Phân tích các thử nghiệm không thành công:

HÀNH ĐỘNG THỬ NGHIỆM	PHIÊN BẢN/SCORE	KẾT QUẢ VÀ LÝ DO THẤT BẠI
Điền khuyết phức tạp (Imputation)	Version 3	Giảm độ chính xác: 0.76315 (So với V2: 0.76794).
Kỹ thuật: Thử nghiệm điền khuyết phức tạp hơn cho Age và Cabin bằng cách sử dụng IterativeImputer (hoặc KNNImputer).	Version 3	Lý do thất bại: Việc này không mang lại lợi ích vì Cabin có quá nhiều missing values (V1 ghi nhận Cabin thiếu 687 hàng), dẫn đến sai số cao khi huấn luyện mô hình dự đoán cho Cabin bằng cách dùng Pclass làm biến dự đoán.
Kết hợp mô hình và Thay đổi Feature Selection	Version 22-23	Giảm độ chính xác khi submit.
Kỹ thuật 1 (Ensemble): Thử nghiệm sử dụng kỹ thuật Voting Classification (kết hợp nhiều mô hình: Logistic Regression, Random Forest, XGBoost).	Version 22-23	Lý do thất bại: Thử nghiệm Voting Classification hoặc thay đổi chiến lược drop/bỏ drop feature đã dẫn đến việc giảm độ chính xác. (Mặc dù việc drop các cột trong V25-27 có thể tăng chỉ số trên tập X_val, nhưng lại gây giảm score khi submit do overfit).

Tinh chỉnh cuối cùng và chọn feature(version 28)



Kết quả

Hạng mục	Phiên bản	Điểm số Tối ưu khi Submit (Accuracy)	Động lực Chính
KẾT QUẢ ĐẠT ĐƯỢC	V28	0.80143	Feature Selection chiến lược
Mô hình Cơ sở	V1	0.74880	Random Forest / Xử lý Missing Value cơ bản
Bước đột phá	V24	0.79904	Feature Family_Survival + Scaling