




BÁO CÁO CHALLENGE 1 - TITANIC


TỐI ƯU HÓA MÔ HÌNH DỰ ĐOÁN TỶ LỆ SỐNG SÓT TITANIC THÔNG QUA KỸ THUẬT FEATURE ENGINEERING LẶP LẠI

Trần Hồ Minh Hải, Trương Văn Thiện, Phan Đức Nhân, Võ Gia Kiệt





Agenda

1. Giới thiệu
 2. Công việc liên quan
 3. Phương pháp được đề xuất
 4. Thực nghiệm và Thảo luận
 5. Kết luận
- 

1. Giới thiệu

Bối cảnh bài toán:

- **Mục tiêu chính:** Xây dựng mô hình phân loại (Classification Model) để dự đoán khả năng sống sót (Survived) của hành khách trên tàu Titanic.
- **Bài toán dự đoán nhị phân (Binary Prediction):** đòi hỏi mô hình phải học được mối quan hệ phức tạp giữa các thuộc tính cá nhân và khả năng sống sót.

Mục Tiêu Cốt Lõi

- Mục tiêu chính là tối ưu hóa hiệu suất dự đoán của mô hình và đạt được điểm chính xác (Score) cao nhất có thể trên tập dữ liệu thử nghiệm.
- Phương pháp đạt được sự tối ưu này là thông qua việc xử lý dữ liệu đầu vào chuyên sâu, đặc biệt là: Kỹ thuật Tạo Đặc trưng Lặp lại (Iterative Feature Engineering).
- Tinh chỉnh các chiến lược Xử lý Giá trị Khuyết thiếu (Missing Value).

2. Công việc liên quan

Thiết lập mô hình cơ sở (Version 1)

- **Xử lý dữ liệu bị mất (Missing Values):** dùng giá trị mean (giá trị trung bình) cho thuộc tính Age, Fare và Embarked dùng mode (giá trị có tần suất xuất hiện nhiều nhất). Cột Cabin bị drop (xóa) do thiếu quá nhiều dữ liệu.

Thuộc tính / Tập dữ liệu	Tập train	Tập test
Age	mean	mean
Fare	-	mean
Embarked	mode	-
Cabin	drop	drop

- **Kỹ thuật Feature Engineering (FE):** cột Sex được mã hóa nhị phân map (male - 0, female - 1) sẽ giúp tăng hiệu suất do thuộc tính Sex có tác động lớn đến biến mục tiêu Survived [1]. Thuộc tính Fare áp dụng biến đổi $\ln$ và được scale với Age. Bên cạnh đó, sử dụng phương pháp One-hot encoding - `pd.get_dummies` với cột Embarked thành các cột nhị phân. Mục đích của các việc xử lý biến đổi các cột mang giá trị nhị phân (0-1) sẽ giúp các mô hình có thể học tốt hơn [2].


[1] Aakriti Singh, Shipra Saraswat, Neetu Faujdar, Analyzing Titanic disaster using machine learning algorithms, Greater Noida, India: IEEE, 2017.

[2] Jerome H. Friedman, Robert Tibshirani, Trevor Hastie, The Elements of Statistical Learning, Springer, 2001.

2. Công việc liên quan

Chiến lược Lựa chọn Mô hình

Sau Version 1 (V1), mô hình **Logistic Regression** được chọn làm cốt lõi cho các phiên bản tiếp theo (V2 - V28). Quyết định này dựa trên sự ổn định và hiệu suất cao của Logistic Regression ở các version sau khi một số feature đầu vào đã được chuẩn hóa (scale) và mã hóa one-hot/dummy (pd.get_dummies).



Hình ảnh minh họa hàm Logistic Regression

3. Phương pháp được đề xuất

3.1.khai thác thông tin từ name(version 2)

Nội dung cần triển khai	Chi tiết Kỹ thuật / Điểm chính
Mục tiêu: Phân tích cột Name để tìm ra danh xưng (Title) của hành khách, nhận thấy đây là thông tin có ý nghĩa lớn đối với khả năng sống sót (Domain Knowledge).	Score V2: 0.76794.
Xử lý Missing Value (MV) Cập nhật: Thay đổi chiến lược điền khuyết: Age chuyển sang điền khuyết bằng median (thay vì mean như V1). Fare cũng chuyển sang điền khuyết bằng median.	MV của cột Cabin vẫn được drop (xóa bỏ).
Feature Engineering (FE) chính: Trích xuất name_title (ví dụ: Mr, Mrs, Master, Dr...) từ cột Name. Gom nhóm các title ít phổ biến thành 'Other', chỉ còn 6 categories (Top 5 titles: 'Mr', 'Miss', 'Mrs', 'Master', 'Dr'). Thuộc tính Pclass chuyển sang get_dummies.	
Mô hình Tối ưu: Chuyển từ Random Forest (V1) sang Logistic Regression (V2) vì tính ổn định và hiệu suất cao sau khi dữ liệu được tinh chỉnh.	

3. Phương pháp được đề xuất

3.2. Rời rạc hóa (Categorical Binning)

Nội dung cần triển khai	Chi tiết Kỹ thuật / Điểm chính
Mục tiêu: Cải thiện độ phân giải của các thuộc tính liên tục quan trọng (Fare, Age) bằng cách chia chúng thành các khoảng rời rạc (Category).	Score V9: 0.77751.
Rời rạc hóa Fare (Version 8): Phân loại cột Fare bằng cách sử dụng các khoảng (bins) đã xác định: Tạo ra các Category như 'so_cheap', 'cheap', 'Medium', 'Expensive'.	V8 Score: 0.76794 (Tuy không tăng so với V2 nhưng là bước chuẩn bị quan trọng).
Rời rạc hóa Age (Version 9): Phân loại cột Age (đã điền khuyết) bằng cách sử dụng các khoảng (bins) chiến lược: Phân thành 6 categories (ví dụ: babi, so_young, young, teenager, adult, old).	Kỹ thuật này giúp mô hình Logistic Regression nắm bắt tốt hơn các ngưỡng tuổi quan trọng đối với tỷ lệ sống sót.

3. Phương pháp được đề xuất

3.3. Xây dựng Feature tổ hợp (v21)

Nội dung cần triển khai	Chi tiết Kỹ thuật / Điểm chính
Mục tiêu: Tạo ra các feature tổng hợp (Derived Features) dựa trên quan hệ gia đình/xã hội, giúp mô hình hiểu rõ hơn về bối cảnh hành khách, mở rộng thông tin ngoài các cột thô.	V21 Score: 0.77990.
Các Derived Features được thêm vào: FamilySize: Tổng số thành viên gia đình trên tàu, tính bằng $\text{SibSp} + \text{Parch} + 1$. IsAlone: Cột nhị phân xác định hành khách đi một mình ($\text{FamilySize} = 1$) hay không.	Các cột này được thêm vào để mô hình nắm bắt được ảnh hưởng của việc đi theo nhóm đến khả năng sống sót.
Các Feature liên quan đến Giới tính/Tuổi: Boy: Là con trai dưới 16 tuổi. WomanOrBoy: Là Nữ giới hoặc Boy (nhóm ưu tiên cứu hộ). FarePerPerson: Tính bằng $\text{Fare} / \text{FamilySize}$.	Phiên bản V21 cũng áp dụng Get_dummies cho các thuộc tính Categories có miền giá trị rộng.

3. Phương pháp được đề xuất

3.4. Feature Đột phá Family_Survival (V24)

Nội dung cần triển khai	Chi tiết Kỹ thuật / Điểm chính
Mục tiêu: Giới thiệu feature quan trọng nhất, mang tính đột phá, dựa trên quy tắc rằng các thành viên trong gia đình đi chung thường có chung số phận (Family Survival rule).	V24 Score: 0.79904 (Đây là bước nhảy vọt quan trọng nhất về điểm số).
Kỹ thuật Family Survival: Feature Family_Survival được tạo ra để phản ánh số phận chung của gia đình. Kỹ thuật này sử dụng dữ liệu để tạo ra quy tắc rằng nếu một gia đình đi chung, họ thường có kết quả sống sót/tử vong tương tự nhau.	Sự cải thiện lớn này cho thấy tầm quan trọng của việc mã hóa thông tin xã hội và mối quan hệ gia đình vào mô hình.
FE Khác trong V24: V24 cũng tiếp tục sử dụng Get_dummies cho các thuộc tính Categories có miền giá trị rộng.	

3. Phương pháp được đề xuất

3.5. Đồng bộ hóa và Scaling (V24)


Nội dung cần triển khai	Chi tiết Kỹ thuật / Điểm chính
Mục tiêu: Chuẩn hóa dữ liệu trước khi huấn luyện mô hình Logistic Regression, đảm bảo rằng các thuộc tính có thang đo khác nhau không ảnh hưởng quá mức đến thuật toán.	Kỹ thuật này đặc biệt quan trọng khi sử dụng Logistic Regression (LR), vì LR nhạy cảm với thang đo của feature.
Kỹ thuật Scaling được sử dụng: Sử dụng StandardScaler() từ thư viện sklearn.preprocessing.	StandardScaler giúp biến đổi dữ liệu sao cho chúng có trung bình bằng 0 và độ lệch chuẩn bằng 1.
Phạm vi áp dụng: Kỹ thuật Scaling được áp dụng đồng nhất lên tất cả các cột của cả tập train_data và test_data.	Cần lưu ý: Phải sử dụng fit_transform trên tập huấn luyện (train_data) và chỉ sử dụng transform trên tập kiểm tra (test_data) để tránh rò rỉ dữ liệu.
Kết quả đạt được (V24): Sau khi áp dụng Scaling, mô hình đạt điểm 0.79904, khẳng định sự cần thiết của việc chuẩn hóa dữ liệu cho mô hình LR.	

4. Thực nghiệm và thảo luận

Bảng Tóm tắt Hiệu suất & Các Bước Cải Tiến Chính

Phiên bản	Score	Xử lý chính	Feature Engineering (FE) chính	Kết quả
V1	0.74880	Age/Fare: Mean, Embarked: Mode, Cabin: Drop	Sex map (0-1), Scale Age/Fare, Drop Name/Ticket	Baseline (Random Forest)
V2	0.76794	Age/Fare: Median	Title từ Name → get_dummies, Pclass dummies	1.9 điểm – cải thiện mạnh nhờ Title (LogReg)
V9	0.77751	Giữ MV như V2	Age binning (phân loại theo nhóm tuổi)	Điểm tăng nhẹ, mô hình ổn định hơn
V21	0.77990	Giữ MV như trước	xây dựng các Feature Tổ hợp (Derived Features)	Cung cấp bối cảnh sâu hơn về hành khách trên tàu
V24	0.79904	Giữ MV như trước	Family_Survival, FamilySize, IsAlone, Scaling toàn bộ	Bước nhảy lớn nhờ feature quan hệ gia đình
V28	0.80143	Giữ MV như trước	Feature selection – loại bias feature, giữ Title, Age_Cat, Fare_Cat	Hiệu suất cao nhất, giảm nhiễu & overfit

Feature Evolution Highlights”



V2 – “Title” feature: → Việc trích xuất danh xưng (“Mr”, “Miss”, “Master”) từ Name giúp mô hình phân biệt giới tính, tầng lớp xã hội, từ đó tăng độ chính xác đáng kể.

V24 – “Family_Survival” feature: → Biến này tận dụng thông tin gia đình đồng hành, giúp mô hình nhận diện xác suất sống sót theo nhóm, tạo bước nhảy lớn thứ hai về hiệu suất.

4. Thực nghiệm và thảo luận

Thảo luận về thất bại và Bài học

Bảng tóm tắt thất bại

Phiên bản	Thay đổi chính	Kết quả(Score)	Nhận xét / Nguyên nhân giảm
V3	Thử IterativeImputer cho MV, thêm CabinGroup	0.743xx (↓ so với V2)	Mất ổn định do mô hình xử lý cabin nhiều, Imputer tạo giá trị “ảo” thiếu thực tế.
V22-V23	Áp dụng Voting Classifier (kết hợp nhiều mô hình)	0.785xx (↓ so với V21-V24)	Ensemble phức tạp gây overfit; mô hình mất cân bằng giữa bias-variance.

Bài học rút ra

⚠ **IterativeImputer** không phải lúc nào cũng cải thiện — cần kiểm soát dữ liệu có phân phối bất thường.

🚫 **Cabin feature** có quá nhiều missing values → nên loại bỏ hoặc nhóm đơn giản.

🤖 **Voting / Ensemble** quá phức tạp có thể làm giảm tính khái quát, không luôn tốt hơn mô hình đơn.

==> Mô hình Logistic Regression với FE chọn lọc vẫn cho hiệu quả ổn định và dễ kiểm soát nhất.

⚙️ *Thất bại của một số phiên bản cho thấy: mô hình không ổn định nếu thay đổi kỹ thuật quá phức tạp — đơn giản, hợp lý và kiểm soát tốt dữ liệu vẫn mang lại hiệu quả cao nhất.*

4. Thực nghiệm và thảo luận

Tình hình Cuối cùng và Feature Selection (V28)

- **Chiến lược tinh giảm Feature**

- Chiến lược: Mục tiêu là giảm số lượng cột và tăng hiệu suất tối đa cho mô hình (Logistic Regression)
- Việc loại bỏ các cột không tác động nhiều đến quá trình huấn luyện và chỉ giữ lại những cột có tác động mạnh mẽ giúp mô hình trở nên gọn gàng hơn và tránh được hiện tượng quá khớp (overfit) với dữ liệu huấn luyện, đặc biệt sau khi đã thêm nhiều feature tổ hợp (như trong V21 và V24).

- **Kết quả Đạt được (V28 Score)**

527

Haitran1207



0.80143

- **Feature Selection: Các Thuộc tính Bị Loại bỏ**

- Boy và WomanOrBoy
- FarePerPerson
- Các cột gốc như Age, Fare (giá trị liên tục) cũng đã được loại bỏ ở giai đoạn này vì chúng đã được thay thế bằng các phiên bản dạng Category (Age_Cat, Fare_Cat) và biến đổi khác (Family_Survival)

4. Thực nghiệm và thảo luận

Tình hình Cuối cùng và Feature Selection (V28)

- Tập Feature Cuối cùng được Giữ lại

Loại Feature	Ví dụ về Cột được giữ lại (Sau khi One-Hot Encoding/Dummies)	Chi tiết
Feature về Danh xưng (Title)	Title1 – Title5 (Ví dụ: name_title_Mr, name_title_Mrs, name_title_Master,...)	Các cột được tạo ra sau khi biến đổi cột 'Title' thành các biến giả (dummies).
Feature về Giá vé (Fare Cat)	Fare_Cat_... (Ví dụ: Fare_Cat_cheap, Fare_Cat_Medium, Fare_Cat_Expensive,...)	Các cột được tạo ra sau khi rời rạc hóa (Categorical Binning) cột Fare và chuyển thành biến giả.
Feature về Tuổi (Age Cat)	Age_Cat_... (Ví dụ: Age_Cat_so_young, Age_Cat_old,...)	Các cột được tạo ra sau khi rời rạc hóa cột Age (Age_Imputed) và chuyển thành biến giả.
Feature Đột phá	Family_Survival	Feature dựa trên quy tắc sinh tồn của gia đình (được thêm vào từ V24).
Các Feature cơ bản khác	Pclass, Sex, SibSp, Parch, Embarked, FamilySize, IsAlone	Các biến đã được xử lý (như Sex thành 0/1, Embarked thành dummies) và các feature tổng hợp (trừ những cái bị loại bỏ).

5. Kết luận

Báo cáo khẳng định rằng Feature Engineering là động lực chính trong việc tối ưu hóa mô hình Titanic.

- **Xử lý missing values:** điền khuyết Age và Fare bằng median (từ V2) và loại bỏ (drop) cột Cabin vì khó xử lý.
- **Xử lý Feature Engineering:** FE tập trung vào khai thác Title (V2) và Family_Survival (V24), sau đó chuẩn hóa (Scaling) và lựa chọn feature chiến lược (V28) để tinh chỉnh bộ feature.
- **Kết quả đạt được:** Mô hình Logistic Regression đã tăng điểm từ V1 (0.74880) lên tối ưu 0.80143 (V28) nhờ các feature được làm sạch và chuẩn hóa



THANK YOU

For your attention

