



Tối ưu hóa mô hình dự đoán tỉ lệ sống sót Titanic thông qua kỹ thuật Feature engineering lặp lại

Trần Hồ Minh Hải, Trương Văn Thiện, Phan Đức Nhân, Võ Gia Kiệt

1. Giới thiệu

Xác định vấn đề:

- input:** tập dữ liệu Titanic từ kaggle
- output:** dự đoán khả năng sống sót của các hành khách trên chuyến tàu Titanic gặp tai nạn


Thách thức:

- Dữ liệu thô chứa nhiều khuyết điểm
- Gồm nhiều cột ít tác động đến target

Dataset

- 891 dữ liệu train, 418 dữ liệu test
- Nguồn dữ liệu: <https://www.kaggle.com/competitions/titanic>

Tỷ lệ Sống Sót và Tử Vong trên Tàu Titanic



2. Phân tích khám phá dữ liệu

- Số lượng giá trị bị thiếu


Thuộc Tính	Số lượng Missing	Tỉ lệ
Age	177	19.8%
Cabin	687	77.1%
Embarked	2	nhỏ không đáng kể

Train

Thuộc Tính	Số lượng Missing	Tỉ lệ
Age	86	20.6%
Cabin	327	78.2%
Fare	1	nhỏ không đáng kể

Test

- Ma trận tương quan



4 thuộc tính tương quan cao với target


Pclass	-0.34
Fare	0.26
Age	-0.07
Parch	0.08

- Pclass tương quan âm mạnh những người có Pclass 1 thường có tỉ lệ sống sót cao hơn
- Fare tương quan dương mạnh: những người có giá vé cao thì thường có khả năng sống sót cao hơn
- Age tương quan âm yếu không nói lên được gì
- Parch tương quan dương yếu không nói lên được gì

Kết Luận

3. Tổng quan quy trình

Các quy trình thực hiện chính:



4. Phương pháp đề xuất

Đối với các giá trị bị thiếu (missing value):

- Age:** Sử dụng giá trị Median để điền khuyết
- Fare:** Sử dụng giá trị Median để điền khuyết
- Embarked:** Sử dụng giá trị Mode (giá trị xuất hiện nhiều nhất)
- Cabin:** Drop cột này do quá nhiều dữ liệu bị thiếu

Kỹ thuật Khai thác Đặc trưng (Feature Engineering - FE):

- Xử lý và mã hóa (Encoding):

- Sex:** male thành 0 và female thành 1
- Pclass và Embarked:** Áp dụng One-Hot Encoding bằng get_dummies
- Name:** Trích xuất danh xưng (Title) từ cột Name (ví dụ: Mr, Mrs, Master)

- Rời rạc hóa (Categorical Binning)

- Fare và Age:** Chuyển Fare và Age thành dạng Category (Fare_cat và Age_cat) sử dụng các bins


- Tạo Feature Tổ hợp (Derived Features):

- FamilySize:** SibSp + Parch + 1
- IsAlone:** Đánh dấu 1 nếu FamilySize = 1

- Family_Survival:** Tạo quy tắc dựa trên việc các thành viên trong gia đình (xác định qua Last_Name và/hoặc Ticket) thường có chung số phận sống sót hoặc tử nạn

5. Đánh giá mô hình

Đánh giá Các mô hình



6. Thử nghiệm mô hình

Thí nghiệm 1 - Trên tập X_Val

Version	Model	Num_Features	Accuracy	F1 Score	ROC_AUC
V1	Random Forest	8	0.8212	0.7385	0.8345
V2	Logistic Regression	14	0.8436	0.7879	0.8701
V9	Logistic Regression	18	0.8436	0.7879	0.8791
V24	Logistic Regression	24	0.8380	0.7914	0.9060
V28	Logistic Regression	23	0.8380	0.7914	0.9072

Thí nghiệm 2 - Trên tập X_Test

Version	Model	Num_Features	Submit_Score
V1	RandomForest	8	0.74880
V2	LogisticRegression	14	0.76794
V9	LogisticRegression	18	0.77751
V24	LogisticRegression	24	0.79904
V28	LogisticRegression	23	0.8013

7. Kết luận

	Phiên bản	Điểm số Tối ưu khi Submit (Accuracy)	Động lực Chính
KẾT QUẢ ĐẠT ĐƯỢC	V28	0.80143	Feature Selection chiến lược
Mô hình Cơ sở	V1	0.74880	Random Forest / Xử lý Missing Value cơ bản
Bước đột phá	V24	0.79904	Feature Family_Survival + Scaling

Mô hình tốt nhất:
LogisticRegression: V28
kết quả khi submit lên
kaggle