





BÁO CÁO CHALLENGE 1 - TITANIC

TỐI ƯU HÓA MÔ HÌNH DỰ ĐOÁN TỶ LỆ SỐNG SÓT TITANIC THÔNG QUA KỸ THUẬT FEATURE ENGINEERING LẶP LẠI


Trần Hồ Minh Hải, Trương Văn Thiện, Phan Đức Nhân, Võ Gia Kiệt





Agenda

1. Giới thiệu
 2. Công việc liên quan
 3. Phương pháp được đề xuất
 4. Thực nghiệm và Thảo luận
 5. Kết luận
- 




1. Giới thiệu

Bối cảnh bài toán:

- **Mục tiêu chính:** Xây dựng mô hình phân loại (Classification Model) để dự đoán khả năng sống sót (Survived) của hành khách trên tàu Titanic.
- **Bài toán dự đoán nhị phân (Binary Prediction):** đòi hỏi mô hình phải học được mối quan hệ phức tạp giữa các thuộc tính cá nhân và khả năng sống sót.

Mục Tiêu Cốt Lõi

- Mục tiêu chính là tối ưu hóa hiệu suất dự đoán của mô hình và đạt được điểm chính xác (Score) cao nhất có thể trên tập dữ liệu thử nghiệm.
- Phương pháp đạt được sự tối ưu này là thông qua việc xử lý dữ liệu đầu vào chuyên sâu, đặc biệt là: Kỹ thuật Tạo Đặc trưng Lặp lại (Iterative Feature Engineering).
- Tinh chỉnh các chiến lược Xử lý Giá trị Khuyết thiếu (Missing Value).



1. Giới thiệu

Dữ liệu bài toán:

- Bộ dữ liệu Titanic từ Kaggle (891 mẫu huấn luyện, 418 mẫu kiểm thử).

Tên cột (Feature)	Ý nghĩa (Tiếng Việt)	Giải thích / Ghi chú
PassengerId	Mã khách hàng	Mã định danh duy nhất của hành khách
Survived	Trạng thái sống	0 = Không sống sót, 1 = Sống sót
Pclass	Hạng vé	1 = Hạng nhất, 2 = Hạng hai, 3 = Hạng ba
Name	Họ tên khách hàng	Họ và tên đầy đủ của hành khách
Sex	Giới tính	Nam (male) hoặc Nữ (female)
Age	Độ tuổi	Tuổi của hành khách (có thể bị thiếu dữ liệu)
SibSp	Số lượng anh/chị/em hoặc vợ/chồng đi cùng	Siblings/Spouses Aboard
Parch	Số lượng cha/mẹ hoặc con đi cùng	Parents/Children Aboard
Ticket	Số vé	Mã số vé của hành khách
Fare	Giá vé khách trả	Tổng số tiền hành khách trả cho vé (đơn vị: bảng Anh)
Cabin	Số cabin	Mã số phòng / khoang trên tàu (thường bị thiếu nhiều)
Embarked	Nơi lên tàu	C = Cherbourg, Q = Queenstown, S = Southampton

2. Công việc liên quan

Model :


Logistic Regression: Mô hình tuyến tính cho bài toán nhị phân

Feature Engineering :

Tạo các cột Feature mới như FamilySize, FamilySize_Survival, Title, IsAlone, Fare_Cat, Age_Cat


Tạo quy tắc Ticket để nâng cao hiệu suất mô hình

Điền các giá trị thiếu bằng trung vị



3. Phương pháp được đề xuất


3.1. Quy trình chính



Model Training : Logistic Regression


3. Phương pháp được đề xuất

3.2. Exploratory data analysis (EDA) và nhận xét



Biểu đồ thể hiện các cột của dữ liệu (theo trục dọc) và các dòng dữ liệu (theo trục ngang).

Màu sáng (1) = giá trị bị thiếu (NaN), màu tối (0) = có dữ liệu.



Đây là feature mạnh nhất trong Titanic dataset — giới tính (Sex) giúp mô hình phân biệt sống/chết rất rõ.

Khi huấn luyện mô hình (logistic regression, random forest, v.v.), biến Sex thường có trọng số lớn nhất (feature importance cao).

3. Phương pháp được đề xuất

3.3.Feature engineering

Tên cột (Feature Name)	Ý nghĩa / Giải thích
Family_Survival	Tính năng biểu thị khả năng sống sót của hành khách dựa trên việc người thân (có cùng họ hoặc số vé) của họ có sống sót hay không. Dùng để bổ sung thông tin xã hội liên quan.
Age_Cat	Phân loại độ tuổi thành nhóm (ví dụ: <i>Child</i> , <i>Teen</i> , <i>Adult</i> , <i>Senior</i>), giúp mô hình hiểu quan hệ phi tuyến giữa tuổi và khả năng sống sót.
Title	Danh xưng trong tên hành khách (Mr, Mrs, Miss, Master, v.v.), thể hiện giới tính, độ tuổi, tầng lớp xã hội. Đây là feature rất quan trọng trong Titanic.
FamilySize	Tổng số thành viên trong gia đình đi cùng ($SibSp + Parch + 1$). Dùng để xác định hành khách đi một mình hay theo nhóm.
IsAlone	Biến nhị phân: =1 nếu hành khách đi một mình, =0 nếu đi cùng người thân. Có ảnh hưởng lớn đến khả năng sống sót.
Fare_Cat	Phân loại giá vé (Low / Medium / High) bằng cách chia Fare thành các nhóm, giúp giảm ảnh hưởng của giá trị ngoại lai.

3. Phương pháp được đề xuất

3.4. Xử lý missing values

Age có nhiều giá trị thiếu (177 hàng trong tập huấn luyện).

- Phương pháp được chọn là điền khuyết bằng giá trị median (trung vị)

Thuộc tính Embarked (Cảng khởi hành):

- Điền bằng giá trị phổ biến nhất (mode)


	MissingCount	MissingPercent
Age	177	19.865320
Embarked	2	0.224467

3. Phương pháp được đề xuất

3.5. Chuẩn hoá dữ liệu và Scaling

“Cả Age và Fare có phân phối không đồng đều; đặc biệt Fare bị lệch mạnh → cần log-transform và chuẩn hoá trước khi đưa vào mô hình để đảm bảo cân bằng và ổn định quá trình học.”

Áp dụng Log
Transformation
cho Fare và Age




3. Phương pháp được đề xuất


3.6. Huấn luyện mô hình

Mô hình được lựa chọn là Logistic Regression

- Lý do lựa chọn: Sau khi thử nghiệm với Random Forest trong Version 1 (đạt 0.74880), mô hình cốt lõi đã được chuyển sang Logistic Regression từ Version 2. Quyết định này được đưa ra vì Logistic Regression cho thấy tính ổn định và hiệu suất cao khi các feature đầu vào đã được tiền xử lý, chuẩn hóa (scale) và mã hóa one-hot/dummy (get_dummies) một cách kỹ lưỡng



Random Forest




3. Phương pháp được đề xuất

3.7. Đánh giá mô hình

Tránh Overfitting trên tập Validation đơn lẻ:

Xác minh chất lượng Feature Engineering





Trong bài toán Phân loại nhị phân (như dự đoán sống sót trên Titanic), việc sử dụng Stratified K-Fold là cần thiết

== > Huấn luyện và đánh giá mô hình 10 lần, sau đó lấy giá trị trung bình của các chỉ số (Accuracy, F1 Score, ROC AUC).

4. Thực nghiệm và thảo luận

Kết quả của cross-validation và hiệu suất của Logistic



→ Cho thấy mô hình dự đoán đúng/nhầm số lượng sống sót (1) và không sống (0).

4. Thực nghiệm và thảo luận

- Kết quả Đạt được (V28 Score)

527	Haitran1207		0.80143
-----	-------------	---	---------

- **Feature Selection: Các Thuộc tính Bị Loại bỏ**
 - Boy và WomanOrBoy
 - FarePerPerson
 - Các cột gốc như Age, Fare (giá trị liên tục) cũng đã được loại bỏ ở giai đoạn này vì chúng đã được thay thế bằng các phiên bản dạng Category (Age_Cat, Fare_Cat) và biến đổi khác (Family_Survival)

4. Thực nghiệm và thảo luận

- Tập Feature Cuối cùng được Giữ lại

Loại Feature	Ví dụ về Cột được giữ lại (Sau khi One-Hot Encoding/Dummies)	Chi tiết
Feature về Danh xưng (Title)	Title1 – Title5 (Ví dụ: name_title_Mr, name_title_Mrs, name_title_Master,...)	Các cột được tạo ra sau khi biến đổi cột 'Title' thành các biến giả (dummies).
Feature về Giá vé (Fare Cat)	Fare_Cat_... (Ví dụ: Fare_Cat_cheap, Fare_Cat_Medium, Fare_Cat_Expensive,...)	Các cột được tạo ra sau khi rời rạc hóa (Categorical Binning) cột Fare và chuyển thành biến giả.
Feature về Tuổi (Age Cat)	Age_Cat_... (Ví dụ: Age_Cat_so_young, Age_Cat_old,...)	Các cột được tạo ra sau khi rời rạc hóa cột Age (Age_Imputed) và chuyển thành biến giả.
Feature Đột phá	Family_Survival	Feature dựa trên quy tắc sinh tồn của gia đình (được thêm vào từ V24).
Các Feature cơ bản khác	Pclass, Sex, SibSp, Parch, Embarked, FamilySize, IsAlone	Các biến đã được xử lý (như Sex thành 0/1, Embarked thành dummies) và các feature tổng hợp (trừ những cái bị loại bỏ).

5. Kết luận

Báo cáo khẳng định rằng Feature Engineering là động lực chính trong việc tối ưu hóa mô hình Titanic.

- **Xử lý missing values:** điền khuyết Age và Fare bằng median và loại bỏ cột Cabin vì khó xử lý.
- **Xử lý Feature Engineering:** FE tập trung vào khai thác Title và Family_Survival , sau đó chuẩn hóa (Scaling) và lựa chọn feature chiến lược để tinh chỉnh bộ feature.
- **Kết quả đạt được:** Mô hình Logistic Regression cho kết quả tốt nhất 0.80143 nhờ các feature được làm sạch và chuẩn hóa



THANK YOU

For your attention

