

Báo cáo challenge 1 – Titanic: Tối ưu hóa Mô hình Dự đoán tỷ lệ Sống Sót Titanic thông qua Kỹ thuật Feature Engineering Lặp lại

Trần Hồ Minh Hải, Trương Văn Thiện, Phan Đức Nhân,
Võ Gia Kiệt

Tóm tắt

Nghiên cứu này trình bày một quá trình tối ưu hóa lặp lại nhằm giải quyết bài toán Dự đoán khả năng sống sót (Binary Classification) của hành khách trên tàu Titanic. Báo cáo tập trung vào Kỹ thuật Khai thác Đặc trưng (Feature Engineering) chuyên sâu và tinh chỉnh chiến lược xử lý dữ liệu thô để nâng cao hiệu suất mô hình. Quá trình tiền xử lý bao gồm việc xử lý giá trị bị mất và chuyển đổi dữ liệu phi cấu trúc thành các đặc trưng có giá trị dự đoán cao và tạo ra các biến tổ hợp mới. Thông qua việc đánh giá nhiều thuật toán học máy, mô hình Hồi quy Logistic (Logistic Regression) được xác định là phương pháp tối ưu. Chiến lược này đã giúp cải thiện độ chính xác dự đoán trên tập dữ liệu kiểm tra, chứng minh tầm quan trọng của việc xử lý dữ liệu đầu vào trong việc xây dựng mô hình học máy hiệu quả.

Chữ viết thường	Chữ viết tắt
Version 1	V1
Version 2	V2
Version 9	V9
Version 21	V21
Version 24	V24
Version 28	V28
Feature Engineering	FE
Missing Values	MV

Table 1. Bảng các cụm từ viết tắt

1. Giới thiệu

1.1. Bối cảnh và mục tiêu

Bài toán đặt ra là xây dựng một mô hình dự đoán khả năng sống sót của hành khách trên tàu Titanic dựa trên dữ liệu lịch sử. Dữ liệu thô thường chứa nhiều khuyết điểm như các giá trị bị thiếu (missing values) và các cột không liên quan, đòi hỏi phải áp dụng các kỹ thuật tiền xử lý và kỹ thuật feature chuyên sâu.

Thuộc tính / Dữ liệu	Tập train	Tập test
Age	177	86
Cabin	687	327
Embarked	2	0
Fare	0	1

Table 2. Bảng số dòng bị mất dữ liệu ở các thuộc tính

1.2. Tổng quan quá trình tối ưu hóa

Mục tiêu chính của nghiên cứu này là đạt được điểm số cao nhất (độ chính xác) thông qua phát triển mô hình lặp lại. Quá trình tối ưu hóa bao gồm nhiều phiên bản thử nghiệm, với các mốc điểm quan trọng như sau:

- Version 1 (V1): 0.74880.
- Version 2 (V2): 0.76794.
- Version 9 (V9): 0.77751.
- Version 21 (V21): 0.77990.
- Version 24 (V24): 0.79904.
- Version 28 (V28): 0.80143.

2. Cơ sở lý thuyết & mô hình cơ sở

2.1. Thiết lập mô hình cơ sở (Version 1)

Mô hình cơ sở Version 1 (V1) được xây dựng với quy trình xử lý dữ liệu một cách đơn giản. Việc xử lý dữ liệu bị mất, ta sẽ dùng giá trị mean (giá trị trung bình) cho thuộc tính Age, Fare và Embarked dùng mode (giá trị có tần suất xuất hiện nhiều nhất). Cột Cabin bị drop (xóa) do thiếu quá nhiều dữ liệu.

Thuộc tính / Tập dữ liệu	Tập train	Tập test
Age	mean	mean
Fare	-	mean
Embarked	mode	-
Cabin	drop	drop

Table 3. Bảng cách xử lý dữ liệu bị mất ở các thuộc tính Version 1

Ở kỹ thuật Feature Engineering (FE), cột Sex được mã hóa nhị phân map (male - 0, female – 1) sẽ giúp tăng hiệu suất do thuộc tính Sex có tác động lớn đến biến mục tiêu Survived [1]. Thuộc tính Fare áp dụng biến đổi $\log$ và được scale với Age. Bên cạnh đó, sử dụng phương pháp One-hot encoding - `pd.get_dummies` với cột Embarked thành các cột nhị phân. Mục đích của các việc xử lý biến đổi các cột mang giá trị nhị phân (0-1) sẽ giúp các mô hình có thể học tốt hơn [2]. Kết quả sau khi huấn luyện, mô hình được sử dụng Random Forest do có đạt accuracy cao nhất khi fit trên tập `x_val`. Public score đạt 0.74880 ở mức ổn nhưng còn hơi thấp.

2.2. Chiến lược Lựa chọn Mô hình

Sau Version 1 (V1), mô hình Logistic Regression được chọn làm cốt lõi cho các phiên bản tiếp theo (V2 - V28). Quyết định này dựa trên sự ổn định và hiệu suất cao của Logistic Regression khi một số feature đầu vào đã được chuẩn hóa (scale) và mã hóa one-hot/dummy (`pd.get_dummies`) [2].

3. Phương pháp kỹ thuật khai thác đặc trưng lặp lại

3.1. Khai thác Name và Cập nhật MV (Version 2)

Bước cải tiến đầu tiên tập trung vào khai thác thông tin từ cột Name, trích xuất ra danh xưng (Title) (ví dụ: Mr, Mrs, Master, Dr,...), việc xử lý này góp phần làm tăng hiệu suất huấn luyện mô hình [1]. Ở giai đoạn xử lý MV, chiến lược điền khuyết được thay đổi, Age và Fare chuyển sang sử dụng giá trị median (giá trị ở giữa) thay vì mean (giá trị trung bình).

Thuộc tính / Tập dữ liệu	Tập train	Tập test
Age	median	median
Fare	-	median
Embarked	mode	-
Cabin	drop	drop

Table 4. Bảng cách xử lý dữ liệu bị mất ở các thuộc tính Version 2

Sang phần xử lý Feature Engineering, Title được trích xuất và gom nhóm, chỉ giữ lại Top 5 Title phổ biến nhất cộng với nhóm ‘Other’ (tổng cộng có 6 categories). Các thuộc tính phân loại như Pclass cũng được chuyển sang `pd.get_dummies`. Kết quả, mô hình Logistic Regression đạt public score là 0.76794 – hiệu suất cao hơn V1.

3.2. Rời rạc hóa thuộc tính Liên tục (Version 8 & 9)

Xử lý MV ở cột Age bằng KNN nhằm tăng độ chuẩn xác hơn trong việc điền khuyết.

Thuộc tính / Tập dữ liệu	Tập train	Tập test
Age	KNN	KNN
Fare	-	median
Embarked	mode	-
Cabin	drop	drop

Table 5. Bảng cách xử lý dữ liệu bị mất ở các thuộc tính Version 8-9

Logistic Regression sẽ cho hiệu suất tốt với tập feature được mã hóa nên để cải thiện độ phân giải thông tin, các thuộc tính liên tục quan trọng là Fare và Age đã được chuyển thành dạng phân loại (Categorical Binning) [2]. Ở Version 8, Fare được phân loại thành các nhóm giá vé bằng pd.cuts. Trong đó Fare sẽ được chia làm 4 khoảng khác nhau tạo thành cột Fare_Cat. Và cột Fare_Cat này sẽ được áp dụng kỹ thuật One-hot encoding – pd.get_dummies để giúp tăng hiệu suất. Ở Version 9, thao tác tương tự được làm với cột Age và chia thành 6 nhóm tuổi tạo thành cột Age_Cat. Cột này cũng sẽ được pd.get_dummies. Kết quả, public score tiếp tục tăng lên 0.77751 (V9).

3.3. Xây dựng Feature Tổ hợp (Version 21)

Xử lý MV không đổi, nhưng lại có thêm nhiều đặc trưng mới được xây dựng. Ở giai đoạn FE, các đặc trưng mới được xây dựng dựa trên mối quan hệ gia đình và xã hội để cung cấp bối cảnh sâu hơn cho mô hình. Các thuộc tính dẫn xuất này bao gồm: FamilySize (= SibSp + Parch + 1), IsAlone (= 1 nếu FamilySize = 1; ngược lại thì bằng 0), FarePerPerson (= Fare / FamilySize), Boy (con trai dưới 16 tuổi), và WomanOrBoy (Female hoặc Boy). Bên cạnh đó trích xuất cụm từ không phải số của ticket để huấn luyện mô hình. Kết quả, public score đạt 0.77990.

3.4. Feature Đột phá: Family_Survival (Version 24)

Xử lý MV không đổi, nhưng lại có thêm đặc trưng mới được xây dựng. Đây là bước nhảy vọt quan trọng nhất về hiệu suất. Cột Family_Survival được tạo ra dựa trên giả định rằng các thành viên trong gia đình đi chung thường có chung số phận sống sót hoặc tử nạn. Thuộc tính này được xây dựng bằng 2 luật: Luật 1 sẽ gộp Last_name + Fare ý chỉ những hộ gia đình đi chung với nhau sẽ có cùng họ và giá vé và kiểm tra tỷ lệ sống sót của hộ gia đình đó; luật 2 sẽ lấy Ticket. Kết quả, public score tăng mạnh lên 0.79904.

3.5. Lựa chọn Feature hợp lý (Version 28)

Chiến lược này bao gồm **loại bỏ** các thuộc tính có thể gây khó khăn đến việc huấn luyện mô hình, cụ thể là các cột: Ticket_Cat, và FarePerPerson. Tập feature cuối cùng được giữ lại để huấn luyện mô hình bao gồm các cột đã được mã hóa hoặc các cột dạng số.

Pclass
Sex

SibSp
Parch
Embarked
Boy
WomanOrBoy
FamilySize
Family_Survival
Các cột pd.get_dummies từ cột Title
Các cột pd.get_dummies từ cột Age_Cat
Các cột pd.get_dummies từ cột Fare_Cat
IsAlone

Table 6. Bảng tập các feature để huấn luyện mô hình Version 28

Đây là mô hình hiệu suất tốt nhất, đạt điểm tối ưu 0.80143.

4. Kết quả và phân tích thảo luận

4.1. Đánh giá hiệu suất lặp lại

Version	Public score	Thay đổi FE chính	Mô hình
V1	0.74880	Age: Mean, Fare: log1p, Model: RF	Random Forest
V2	0.76794	MV: Age/Fare -> Median. Feature: Name Title (get_dummies)	Logistic Regression
V9	0.77751	Feature: Age/Fare Categorical Binning	Logistic Regression
V24	0.79904	Feature: Family_Survival + Scaling toàn bộ dữ liệu	Logistic Regression
V28	0.80143	Feature Selection chiến lược	Logistic Regression

Table 7. Bảng tóm tắt so sánh hiệu suất của các phiên bản chính

Phân tích cho thấy khai thác Title (V2) và Family_Survival (V24) là hai động lực chính cho sự cải thiện độ chính xác.

4.2. Phân tích các Thử nghiệm Không thành công

Nghiên cứu cũng ghi nhận các phiên bản làm giảm độ chính xác, giúp chứng minh tính nhạy cảm của mô hình đối với các thay đổi FE không phù hợp. Thứ nhất, Version 3 (0.76315) với việc thử

nghiệm điền khuyết phức tạp hơn cho Age và Cabin bằng IterativeImputer (hoặc KNNImputer) sử dụng Pclass làm biến dự đoán không mang lại lợi ích do Cabin có quá nhiều missing values gây nên sai số cao khi huấn luyện. Thứ hai, Version 22-23 Việc thử nghiệm sử dụng kỹ thuật Voting Classification (kết hợp nhiều mô hình) hoặc thay đổi chiến lược drop/bỏ drop feature đã dẫn đến việc giảm accuracy khi submit.

4.3. Tinh chỉnh Cuối cùng và Lựa chọn Feature (Version 28)

Để đạt được hiệu suất tối đa (V28: 0.80143), chiến lược tinh giảm feature đã được thực hiện. Đầu tiên là Feature Selection: Loại bỏ thuộc tính có tác động ít đến việc huấn luyện, bao gồm: Ticket_Cat và FarePerPerson. Tập feature cuối cùng được giữ lại chủ yếu bao gồm các cột được tạo ra sau khi mã hóa one-hot các thuộc tính phân loại.

5. Kết luận và Hướng Phát triển Tương lai

5.1. Kết luận

Báo cáo khẳng định rằng Feature Engineering là động lực chính trong việc tối ưu hóa mô hình Titanic. Việc khai thác thành công các feature tiềm ẩn như Title và Family_Survival, kết hợp với việc chuẩn hóa (Scaling) và lựa chọn feature chiến lược (V28), đã giúp mô hình Logistic Regression đạt điểm số tối ưu 0.80143.

5.2. Hướng Phát triển Tương lai

Trong tương lai có thể phát triển mô hình bằng cách tinh chỉnh siêu tham số (Hyperparameter Tuning) sâu hơn cho mô hình Logistic Regression trên bộ feature V28 đã được làm sạch. Bên cạnh đó, thử nghiệm các mô hình mạnh hơn (ví dụ: XGBoost hoặc Voting Classifier) sử dụng chính bộ feature tối ưu từ V28 để tìm kiếm khả năng vượt qua mốc 0.80143.

References

- [1] Aakriti Singh, Shipra Saraswat, Neetu Faujdar, Analyzing Titanic disaster using machine learning algorithms, Greater Noida, India: IEEE, 2017.
- [2] Jerome H. Friedman, Robert Tibshirani, Trevor Hastie, The Elements of Statistical Learning, Springer, 2001.