



Xây dựng mô hình máy học để dự đoán giá nhà

Trần Hồ Minh Hải, Trương Văn Thiện, Phan Đức Nhân, Võ Gia Kiệt

1. Giới thiệu

Xác định vấn đề:

- input:** tập dữ liệu House Price từ Kaggle
- output:** dự đoán giá nhà trong tương lai

Thách thức:

- Dữ liệu thô chứa nhiều khuyết điểm
- Gồm 80 feature khó xử lý và chọn lọc
- Nhiều feature chứa nhiều missing value và ít ảnh hưởng đến target

Dataset

- 1460 dữ liệu train, 1460 dữ liệu test
- Nguồn dữ liệu: <https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/data>

Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	LotShape	LandContour	Utilities	LotConfig	GarageArea	GarageCond	PavedDrive	OpenPorchSF	MoSold	YrSold	SaleType	SaleCondition
0	1	60	RL	65.0	B450	Pave	Reg	Lvl	AllPub	Inside	---	---	---	---	---	---	---
1	2	20	RL	80.0	9600	Pave	Reg	Lvl	AllPub	FR2	---	---	---	---	---	---	---
2	3	60	RL	68.0	11250	Pave	IR1	Lvl	AllPub	Inside	---	---	---	---	---	---	---
3	4	70	RL	60.0	9550	Pave	IR1	Lvl	AllPub	Corner	---	---	---	---	---	---	---
4	5	60	RL	84.0	14260	Pave	IR1	Lvl	AllPub	FR2	---	---	---	---	---	---	---
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1455	1456	60	RL	62.0	7917	Pave	Reg	Lvl	AllPub	Inside	---	---	---	---	---	---	---
1456	1457	20	RL	85.0	13175	Pave	Reg	Lvl	AllPub	Inside	---	---	---	---	---	---	---
1457	1458	70	RL	66.0	9042	Pave	Reg	Lvl	AllPub	Inside	---	---	---	---	---	---	---
1458	1459	20	RL	68.0	9717	Pave	Reg	Lvl	AllPub	Inside	---	---	---	---	---	---	---
1459	1460	20	RL	75.0	9937	Pave	Reg	Lvl	AllPub	Inside	---	---	---	---	---	---	---

2. Phân tích khám phá dữ liệu

Các cột có trên 40% số lượng missing value


Train

Thuộc Tính	Số lượng Missing	Tỉ lệ
Alley	1369	93.77%
MasVnrType	872	59.73.1%
FireplaceQu	690	47.26%
PoolQC	1453	99.52%
Fence	1179	80.75%
MiscFeature	1406	96.30%


Các cột có trên 50% số lượng giá trị = 0

Thuộc Tính	Số lượng Missing	Tỉ lệ
MasVnrArea	861	58.97%
BsmtFinSF2	1293	88.56%
2ndFlrSF	829	56.78%
LowQualFinSF	1434	98.22%
BsmtFullBath	856	58.63%
BsmtHalfBath	1378	94.38%
HalfBath	913	62.53%
WoodDeckSF	761	52.12%
EnclosedPorch	1252	85.75%
3SsnPorch	1436	98.36%
ScreenPorch	1344	92.05%
PoolArea	1453	99.52%
MiscVal	1408	96.44%

Ma trận tương quan



Biểu đồ scatter: FullBath vs SalePrice (nhiều màu)




Nhìn chung tất cả các cột có kiểu number đều có độ tương quan rất lớn đối với target

Tuy nhiên bộ dữ liệu vẫn còn nhiều cột kiểu object cần phải được chọn lọc và xử lý

3. Tổng quan quy trình

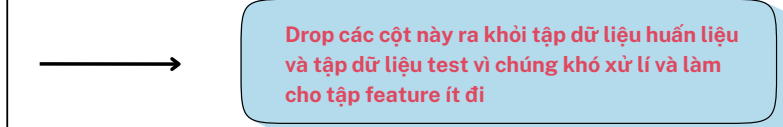
Các quy trình thực hiện chính:




4. Phương pháp đề xuất

Đối với các giá trị có kiểu là number:

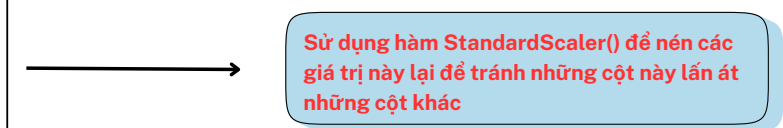
- Xử lý các cột có số lượng missing value lớn hơn 40% và các cột có số lượng giá trị bằng 0 lớn hơn 50%






- Xử lý các cột có số lượng missing value còn lại



- Xử lý các cột mà các giá trị của chúng rất lớn

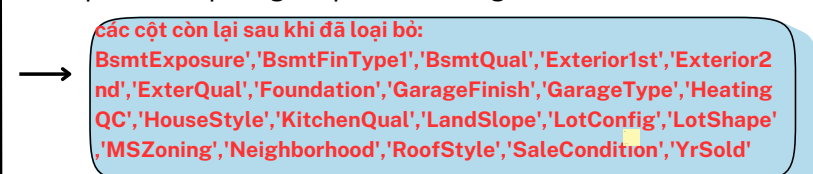


- Tạo thêm các feature tổ hợp

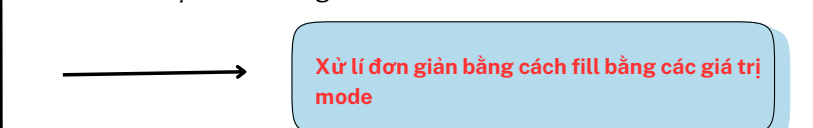


Đối với các cột có kiểu là object:


- Loại bỏ các cột có giá trị mất cân bằng



- Xử lý các cột có missing value



- Xử lý các giá trị object



→ Tổng cộng có 34 features để huấn luyện mô hình

5. Đánh giá mô hình

Đánh giá Các mô hình

RMSE

RMSE: đo mức độ sai lệch trung bình giữa giá trị dự đoán và giá trị thật. RMSE càng nhỏ → mô hình dự đoán càng chính xác.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Trong đó:


- n : số lượng mẫu dữ liệu
- y_i : giá trị thực tế (ground truth)
- $\hat{y}_i$: giá trị dự đoán của mô hình

- Ý nghĩa:

- RMSE càng nhỏ → mô hình dự đoán càng chính xác.
- RMSE = 0 → mô hình dự đoán hoàn hảo (không có sai số).
- Vì sai số được bình phương trước khi lấy trung bình, RMSE phạt nặng các sai số lớn hơn so với sai số nhỏ.

6. Thử nghiệm mô hình

Chia K-Fold để huấn luyện



Chia tập dữ liệu thành 5 phần bằng nhau mỗi 1 lần huấn luyện sẽ học trên 4 phần 1 phần còn lại đánh giá học cho tới khi đủ 5 lần tiến hành lấy trung bình các độ đo để đánh giá các mô hình

Thí nghiệm 1 - Trên 5 K-Fold

Model	RMSE	Public Score
XGB stable	0.13196	0.13886
Lasso Regression	0.14825	0.15387
ElasticNet Regression	0.14905	0.15426
Blending	0.13900	0.13715
Stacking	0.04942	0.13781

- Mô hình Stacking có RMSE train tốt nhất (0.04942) nhưng public score (0.13781) không vượt trội, cho thấy dấu hiệu overfitting.
- Blending thể hiện cân bằng tốt nhất với public score 0.13715 (tốt nhất) và RMSE 0.13900, chứng tỏ hiệu quả thực tế cao.
- XGB Stable cho kết quả ổn định (RMSE: 0.13196, public: 0.13886), là mô hình đơn lẻ đáng tin cậy.
- Lasso và ElasticNet có hiệu suất thấp hơn, phù hợp với nhận định các mô hình linear thường kém hiệu quả với bài toán phức tạp.

→ Blending là lựa chọn tối ưu cho bài toán này khi cân bằng giữa hiệu suất và khả năng tổng quát hóa.

submission_blend.csv	0.13715
----------------------	---------

7. Kết luận

Tầm quan trọng của Feature Engineering: Việc tạo ra các đặc trưng mới có ý nghĩa từ dữ liệu thô đã giúp mô hình nắm bắt tốt hơn các mối quan hệ phức tạp trong dữ liệu.

Kỹ thuật Blending hiệu quả: Việc áp dụng thành công kỹ thuật Blending, kết hợp sức mạnh của các mô hình cơ sở khác nhau, đã tối ưu hóa hiệu suất dự đoán.

Quy trình phân tích toàn diện: Quy trình phân tích dữ liệu, tiền xử lý, kỹ thuật đặc trưng và xây dựng mô hình đã tạo nên một hệ thống dự đoán thống nhất và hiệu quả.

Kết Luận