



Xây dựng mô hình máy học để dự đoán giá nhà

Trần Hồ Minh Hải, Trương Văn Thiện, Phan Đức Nhân, Võ Gia Kiệt

1. Giới thiệu

Xác định vấn đề:

- input:** tập dữ liệu House Price từ Kaggle
- output:** dự đoán giá nhà trong tương lai

Thách thức:

- Dữ liệu thô chứa nhiều khuyết điểm
- Gồm 80 feature khó xử lý và chọn lọc
- Nhiều feature chứa nhiều missing value và ít ảnh hưởng đến target

Dataset

- 1460 dữ liệu train, 1460 dữ liệu test
- Nguồn dữ liệu: <https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/data>

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	LotShape	LandContour	Utilities	LotConfig	GarageArea	GarageCond	PavedDrive	OpenPorchSF	MoSold	YrSold	SaleType	SaleCond
0	1	60	RL	65.0	8450	Pave	Reg	Lvl	AllPub	Inside	548	TA	Y	61	2	2008	WD	No
1	2	20	RL	80.0	9600	Pave	Reg	Lvl	AllPub	FR2	460	TA	Y	0	5	2007	WD	No
2	3	60	RL	68.0	11250	Pave	IR1	Lvl	AllPub	Inside	608	TA	Y	42	9	2008	WD	No
3	4	70	RL	60.0	9550	Pave	IR1	Lvl	AllPub	Corner	642	TA	Y	35	2	2006	WD	Abn
4	5	60	RL	84.0	14260	Pave	IR1	Lvl	AllPub	FR2	836	TA	Y	84	12	2008	WD	No
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1455	1456	60	RL	62.0	7917	Pave	Reg	Lvl	AllPub	Inside	460	TA	Y	40	8	2007	WD	No
1456	1457	20	RL	85.0	13175	Pave	Reg	Lvl	AllPub	Inside	500	TA	Y	0	2	2010	WD	No
1457	1458	70	RL	66.0	9042	Pave	Reg	Lvl	AllPub	Inside	252	TA	Y	60	5	2010	WD	No
1458	1459	20	RL	68.0	9717	Pave	Reg	Lvl	AllPub	Inside	240	TA	Y	0	4	2010	WD	No
1459	1460	20	RL	75.0	9937	Pave	Reg	Lvl	AllPub	Inside	276	TA	Y	68	6	2008	WD	No

2. Phân tích khám phá dữ liệu



Các cột có trên 40% số lượng missing value

Thuộc Tính	Số lượng Missing	Tỉ lệ
Alley	1369	93.77%
MasVnrType	872	59.731%
FireplaceQu	690	47.26%
PoolQC	1453	99.52%
Fence	1179	80.75%
MiscFeature	1406	96.30%


Các cột có trên 50% số lượng giá trị = 0

Thuộc Tính	Số lượng Missing	Tỉ lệ
MasVnrArea	861	58.97%
BsmtFinSF2	1293	88.56%
2ndFlrSF	829	56.78%
LowQualFinSF	1434	98.22%
BsmtFullBath	856	58.63%
BsmtHalfBath	1378	94.38%
HalfBath	913	62.53%
WoodDeckSF	761	52.12%
EnclosedPorch	1252	85.75%
3SsnPorch	1436	98.36%
ScreenPorch	1344	92.05%
PoolArea	1453	99.52%
MiscVal	1408	96.44%

Ma trận tương quan




Biểu đồ scatter: FullBath vs SalePrice (nhiều màu)



3. Tổng quan quy trình

Các quy trình thực hiện chính:



4. Phương pháp đề xuất

Đối với các giá trị có kiểu là number:

- Xử lý các cột có số lượng missing value lớn hơn 40% và các cột có số lượng giá trị bằng 0 lớn hơn 50%

Drop các cột này ra khỏi tập dữ liệu huấn luyện và tập dữ liệu test vì chúng khó xử lý và làm cho tập feature ít đi




- Xử lý các cột có số lượng missing value còn lại

Xử lý đơn giản bằng cách fill bằng các giá trị trung vị (median)

- Xử lý các cột mà các giá trị của chúng rất lớn

Sử dụng hàm StandardScaler() để nén các giá trị này lại để tránh những cột này lấn át những cột khác

- Tạo thêm các feature tổ hợp



Đối với các cột có kiểu là object:

- Loại bỏ các cột có giá trị mất cân bằng

các cột còn lại sau khi đã loại bỏ: BsmtExposure, BsmtFinType1, BsmtQual, Exterior1st, Exterior2nd, ExterQual, Foundation, GarageFinish, GarageType, HeatingQC, HouseStyle, KitchenQual, LandSlope, LotConfig, LotShape, MSZoning, Neighborhood, RoofStyle, SaleCondition, YrSold

- Xử lý các cột có missing value

Xử lý đơn giản bằng cách fill bằng các giá trị mode

- Xử lý các giá trị object

Tiến hành oneHot vector

5. Đánh giá mô hình

Đánh giá Các mô hình

RMSE

RMSE: đo mức độ sai lệch trung bình giữa giá trị dự đoán và giá trị thật. RMSE càng nhỏ → mô hình dự đoán càng chính xác.

Trong đó:


- n : số lượng mẫu dữ liệu
- y_i : giá trị thực tế (ground truth)
- $\hat{y}_i$: giá trị dự đoán của mô hình

Ý nghĩa:

- RMSE càng nhỏ → mô hình dự đoán càng chính xác.
- RMSE = 0 → mô hình dự đoán hoàn hảo (không có sai số).
- Vì sai số được bình phương trước khi lấy trung bình, RMSE phạt nặng các sai số lớn hơn so với sai số nhỏ.

6. Thử nghiệm mô hình

Chia K-Fold để huấn luyện



Chia tập dữ liệu thành 5 phần bằng nhau mỗi 1 lần huấn luyện sẽ học trên 4 phần 1 phần còn lại đánh giá học cho tới khi đủ 5 lần tiến hành lấy trung bình các độ đo để đánh giá các mô hình

Thí nghiệm 1 - Trên 5 K-Fold

Model	RMSE	Public-Score
LassoCV	0.1483	0.15387
XGBoost	0.1418	0.13702
ElasticNetCV	0.1491	0.15426
Blending	0.1390	0.13715
Stacking	0.0781	0.13743

→ Các tham số tối ưu cho mô hình: $n_estimators=1800, learning_rate=0.02, max_depth=3, subsample=0.9, colsample_bytree=0.55, min_child_weight=4, reg_lambda=1.0, reg_alpha=0.01, gamma=0.0, random_state=42, tree_method='hist'$

7. Kết luận

Model	Điểm số Tối ưu khi Submit (Accuracy)	Động lực Chính
XGBoost	0.13702	Feature Selection chiến lược
LassoCV	0.15387	Xử lý Missing Value cơ bản
Blending	0.13715	Kết hợp dự đoán trên nhiều mô hình

Mô hình tốt nhất: XGBoost kết quả khi submit lên kaggle

submission_xgb_lasso_enet.csv
Complete · 1m ago
0.13702

Kết Luận

Nhìn chung tất cả các cột có kiểu number đều có độ tương quan rất lớn đối với target

Tuy nhiên bộ dữ liệu vẫn còn nhiều cột kiểu object cần phải được chọn lọc và xử lý