

TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN



HỌC PHẦN: NHẬP MÔN MÁY HỌC
BÁO CÁO BÀI TẬP NHÓM TUẦN 12

Nhóm sinh viên thực hiện:

Trần Hồ Minh Hải - 3123410092
Trương Văn Thiện - 3123410356
Phan Đức Nhân - 3123410243
Võ Gia Kiệt - 3123410182

TP. HCM THÁNG 11/2025

1. Giới thiệu

Trong chương ML09, nhóm được yêu cầu tìm hiểu và thực hành hai mô hình hồi quy cơ bản trong học máy:

- o Linear Regression – mô hình dự đoán biến liên tục.
- o Logistic Regression – mô hình dự đoán xác suất, thường áp dụng cho bài toán phân loại nhị phân (0/1).

Yêu cầu của bài tập nhóm gồm:

1. Làm bài tập Excel, thực hành các ví dụ và bài tập trong Chương 2 (Linear Regression) và Chương 6 (Logistic Regression) theo file đính kèm.
2. Dựa trên code/ý tưởng Gradient Descent, minh họa quá trình tính toán và cập nhật tham số cho cả hồi quy tuyến tính và logistic.
3. Viết báo cáo tổng hợp lại lý thuyết, công thức, quy trình thực hành trên Excel và phần bài tập vận dụng.

Báo cáo này trình bày lần lượt: cơ sở lý thuyết, quy trình gradient descent, thực hành Excel cho từng mô hình, phần bài tập vận dụng và một số nhận xét, kết luận.

2. Lý thuyết nền tảng

2.1. Linear Regression

2.1.1. Khái niệm

Linear Regression (hồi quy tuyến tính) là mô hình dự đoán trong đó **mối quan hệ giữa biến phụ thuộc y và các biến độc lập x được giả định là tuyến tính**. Khi chỉ có một biến độc lập, mô hình có dạng:

$$y = mx + b$$

Trong đó:

- y : biến phụ thuộc (target).
- x : biến độc lập (independent variable).
- m : hệ số góc (slope).
- b : hệ số chặn (intercept).

Khi có nhiều biến độc lập $x_1, x_2, \dots, x_n$, mô hình mở rộng thành:

$$y = m_1x_1 + m_2x_2 + \dots + m_nx_n + b$$

Bài toán hồi quy tuyến tính là tìm bộ tham số $(m_1, \dots, m_n, b)$ sao cho mô hình “khớp” với dữ liệu huấn luyện tốt nhất.

Trong ngữ cảnh data mining, tập (m, b) chính là **model**.

2.1.2. Phương pháp bình phương tối thiểu (Least Squares)

Với tập dữ liệu huấn luyện (x_i, y_i) sai số (error) giữa giá trị dự đoán $\hat{y}_i$ và giá trị thực y_i được đo bằng hiệu $y_i - \hat{y}_i$.

Phương pháp **Least Squares** sử dụng **tổng bình phương sai số**:

$$E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Mục tiêu là **tìm m và b sao cho E nhỏ nhất**. Sách trình bày chi tiết cách lấy đạo hàm riêng và thu được công thức đóng cho m và b.

2.1.3. Multiple Linear Regression

Khi có nhiều biến độc lập (Temperature, Tourists, Sunny Days...), mô hình trở thành **multiple linear regression**:

$$y = m_1x_1 + m_2x_2 + m_3x_3 + b$$

Trong Excel, hàm **LINEST** trả về một mảng chứa các hệ số m_3, m_2, m_1, b (thứ tự đảo ngược so với cách viết phương trình), vì vậy cần kết hợp thêm hàm **INDEX** để lấy từng hệ số tương ứng.

2.2. Logistic Regression

2.2.1. Khái niệm

Logistic Regression là mô hình thống kê dùng để **ước lượng xác suất xảy ra của một sự kiện**, thường biểu diễn bằng 1 (xảy ra) và 0 (không xảy ra). Ví dụ: bệnh nhân **sống sót sau 5 năm** (1) hay **không sống sót** (0).

Ta ký hiệu:

- Ký hiệu biến đầu ra $Y \in \{0, 1\}$
- $P(1)$ là xác suất sự kiện xảy ra; $P(0) = 1 - P(1)$
- Tỷ số **odds**: $\frac{P(1)}{1-P(1)}$

Giả định chính của logistic regression là **log-odds** là một hàm tuyến tính của các biến độc lập:

$$\ln \ln \frac{P(1)}{1-P(1)} = m_1x_1 + m_2x_2 + \dots + m_nx_n + b$$

Giải phương trình trên theo $P(1)$ ta thu được **hàm logistic** (dạng sigmoid):

$$P(1) = \frac{1}{1 + e^{-(m_1x_1 + \dots + m_nx_n + b)}}$$

Đây chính là công thức được dùng trong file Excel: $=1/(1+\text{EXP}(-H6))$ với $H6 = m_1x_1 + \dots + b$

2.2.2. Likelihood và Log Loss

Thay vì tối ưu trực tiếp $P(1)$, logistic regression tối ưu **likelihood** – tức là “mức độ phù hợp” giữa dự đoán và nhãn thật của từng mẫu:

- Nếu nhãn thật = 1 $\rightarrow$ likelihood = $P(1)$.
- Nếu nhãn thật = 0 $\rightarrow$ likelihood = $P(0) = 1 - P(1)$.

Để thuận tiện cho tính toán và tối ưu, thường dùng **log-likelihood** hoặc **log loss**:

- Log-likelihood: $\log \log (\text{Likelihood})$.

- Log loss (hàm mất mát): **ngịch đảo dấu** của log-likelihood, ví dụ:
 - Nếu $y = 1 \rightarrow \text{loss} = -\log(P(1))$
 - Nếu $y = 0 \rightarrow \text{loss} = -\log(1 - P(1))$

Mục tiêu mô hình:

- **Tối đa hóa tổng log-likelihood** (càng lớn càng tốt).
- Tương đương với **tối thiểu hóa tổng log loss** (càng nhỏ càng tốt).

Trong Excel, việc tối ưu này được thực hiện bằng công cụ **Solver** với phương pháp **GRG Nonlinear**.

3. Gradient Descent

Mặc dù trong Excel ta có thể dùng công thức đóng (Linear) hoặc dùng Solver (Logistic), nhưng trong machine learning hiện đại, cách phổ biến là tối ưu các tham số bằng **Gradient Descent** (GD).

Ý tưởng chung:

- Chọn ngẫu nhiên (hoặc đặt 0) các giá trị ban đầu cho tham số m_j, b .
- Tính **gradient** (đạo hàm của hàm mất mát theo từng tham số).
- Cập nhật tham số theo hướng ngược dấu gradient:

$$\theta := \theta - \alpha \frac{\partial \text{Loss}}{\partial \theta}$$

Trong đó θ là một tham số (một m_j hay b), α là learning rate.

3.1. Gradient Descent cho Linear Regression

Ta dùng hàm mất mát **Mean Squared Error (MSE)**:

$$J(m_1, \dots, m_n, b) = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

với $\hat{y}_i = m_1 x_{i1} + \dots + m_n x_{in} + b$

Đạo hàm theo từng m_j và b :

$$\frac{\partial J}{\partial m_j} = -\frac{2}{N} \sum_{i=1}^N (y_i - \hat{y}_i) x_{ij}, \quad \frac{\partial J}{\partial b} = -\frac{2}{N} \sum_{i=1}^N (y_i - \hat{y}_i)$$

Quy tắc cập nhật:

$$m_j := m_j - \alpha \frac{\partial J}{\partial m_j}, \quad b := b - \alpha \frac{\partial J}{\partial b}$$

3.2. Gradient Descent cho Logistic Regression

Với logistic regression, đầu ra là xác suất:

$$\hat{y} = P(1) = \sigma(z) = \frac{1}{1+e^{-z}}, z = m_1x_1 + \dots + m_nx_n + b$$

Ta dùng **log loss trung bình** cho N mẫu:

$$J(m_1, \dots, m_n, b) = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Đạo hàm của J theo từng tham số có dạng rất gọn:

$$\frac{\partial J}{\partial m_j} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)x_{ij}, \quad \frac{\partial J}{\partial b} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)$$

Quy tắc cập nhật:

$$m_j := m_j - \alpha \frac{\partial J}{\partial m_j}, b := b - \alpha \frac{\partial J}{\partial b}$$

4. Thực hành Excel

4.1 Linear Regression

Table 2-1. Ice cream sale vs. temperature

Temperature (F)	Ice Cream Sale (Thousands of Dollars)
91	89.8
87	90.2
86	81.1
88	83.0
92.8	90.9
95.2	119.0
93.3	94.9
97.7	132.4

	A	B	C	D	E
1	x	y			
2	91	89.8			
3	87	90.2	SUM(X)	731	
4	86	81.1	SUM(Y)	781.3	
5	88	83	SUM(XY)	71851.77	
6	92.8	90.9	SUM(X^2)	66915.06	
7	95.2	119	n	8	
8	93.3	94.9	m	3.83943386	
9	97.7	132.4	b	-253.165769	
10					
11			Scoring Data Prediction		
12			88.8	87.8	
13			96.9	118.9	
14			94.7	110.4	
15					

Dữ liệu

Dữ liệu ví dụ trong chương 2 mô tả mối quan hệ giữa:

- o Nhiệt độ trung bình tuần (Temperature – F)
- o Doanh số kem (Ice Cream Sale – ngàn đô)

Mục tiêu: dự đoán doanh số kem dựa trên nhiệt độ (và sau đó mở rộng thêm biến Tourists, Sunny Days).

Dùng hàm:

- =SLOPE(y_range, x_range)
- =INTERCEPT(y_range, x_range)
- =LINEST(...)

Nhận xét :

- Hệ số tương ứng với **Sunny Days** và **Temperature** có giá trị dương → các biến này làm tăng doanh số kem.
- Hệ số của **Tourists** nhỏ và có thể âm (theo ví dụ trong sách) cho thấy biến này ít ảnh hưởng, hoặc dataset nhỏ khiến hệ số chưa ổn định.
- Excel cho phép tính m, b bằng nhiều cách: thủ công, SLOPE/INTERCEPT, LINEST; giúp hiểu rõ cả mặt toán học lẫn thực hành.

4.2. Logistic Regression

Dữ liệu

- Biểu hiện của 5 gene.
- Nhãn đầu ra: bệnh nhân **sống sót sau 5 năm** (1) hoặc không (0).

Mục tiêu: xây dựng mô hình logistic regression để ước lượng xác suất sống sót và phân loại bệnh nhân.

D	E	F	G	H	I	J	K
3	2	1	6				
m3	m4	m5	b			total diff=	53
-0.00513	-0.00051	-0.00074	0.535574025				
-0.00513	-0.00051	-0.00074	0.535574025				
gene3	gene4	gene5	5-year survival	m1x1+m2x2+ P(1)	Outcome	Difference	
350.9466	11.1876	77.926	0	-0.02392719	0.494018	0	0
2.579007	301.8684	171.9968	0	0.298006125	0.573955	1	1
39.90712	9.2879	104.2632	1	0.373754353	0.592366	1	0
2.420307	14.1677	94.6316	1	0.503845363	0.623363	1	0
5.831751	35.4298	71.0588	0	0.374075115	0.592443	1	1
4.406125	50.444	104.7838	0	0.296268835	0.57353	1	1
28.72168	6.4724	78.3981	0	0.374183693	0.59247	1	1
1.019015	24.3784	146.7328	1	0.410278594	0.601155	1	0

	F	G	H	I	J	K	L	M
1	1	6					To-Minimize	28.72108934
2	m5	b			total Diff =	12		
3	-0.00074	0.535574025						
4	-0.0038	4.222998782						
5	Gene5	5-year survival	m1x1+m2x2+...+b	P(1)	Outcome	Difference	Likelihood	Log loss
6	77.926	0	-35.67431731	3.21248E-16	0	0	1	3.33067E-16
7	171.9968	0	-2.125848326	0.106609769	0	0	0.893390231	0.112731805
8	104.2632	1	-0.642953181	0.344579274	0	1	0.344579274	1.065431101
9	94.6316	1	2.049299492	0.885876817	1	0	0.885876817	0.121177371
10	71.0588	0	-4.987849122	0.006774117	0	0	0.993225883	0.006797165
11	104.7838	0	-6.928861519	0.000978157	0	0	0.999021843	0.000978636
12	78.3981	0	0.392794501	0.596955237	1	1	0.403044763	0.908707649

Dùng hàm

- Linest
- Sumproduct
- Sigmoid
- Solver -> Đặt objective là max
- Cohnj GRG Nonlinear
- Keep Solver Solution

Nhận xét

- Số mẫu phân loại sai giảm còn **12/87**, thể hiện mô hình logistic regression đã được tối ưu tốt hơn nhiều so với hệ số ban đầu từ LINEST.
- Giá trị log-likelihood tăng lên, hoặc tương đương log loss giảm nếu ta chọn cách tối thiểu hoá log loss.

5. Bài tập vận dụng

Chương 2 :

link :

https://docs.google.com/spreadsheets/d/1oRNfq1e6BdJoqtwmFL8e1Lx5nD1_YRYW/edit?gid=1268255652#gid=1268255652

Dữ liệu và mục tiêu

- Dữ liệu là 10 năm tuyển sinh bậc cử nhân của một trường đại học ở Connecticut (2004–2014).
- Biến phụ thuộc (Y):
 - o Number of First Year Enrollment – số sinh viên năm nhất nhập học mỗi năm.
- Các biến độc lập ($X_1 \dots X_9$) gồm:
 - o Num high school graduates (số HS tốt nghiệp THPT trong bang)
 - o USA Economics (tình hình kinh tế / job growth)
 - o Comparable tuition fee (mức học phí so với trường khác)
 - o Financial scholarship (mức độ học bổng)
 - o Financial aid available (mức độ hỗ trợ tài chính)
 - o Number of open house visitors (số lượt tham quan trường)
 - o Media advertisement investment (chi phí quảng cáo)
 - o Admission activities (các hoạt động tuyển sinh)
 - o SAT cutoff (điểm SAT đầu vào)

Mục tiêu: từ dữ liệu 10 năm, xây dựng mô hình multiple linear regression để:

1. Hiểu yếu tố nào ảnh hưởng mạnh tới số lượng sinh viên nhập học.
2. Dùng mô hình để dự đoán enrollment của năm kế tiếp.

Quy trình thực hiện

- **Nhập dữ liệu** 2004–2014 vào Excel, sắp xếp lại thành bảng với Y là “Number of First Year Enrollment”, các cột còn lại là $X_1 \dots X_9$.
- Dùng hàm **LINEST** với cú pháp:
 - =LINEST(Y_range, X_range, TRUE, TRUE)
 - để lấy bộ hệ số $(m_1 \dots m_9, b)$ ($m_1 \dots m_9, b$).
- Do LINEST trả hệ số theo **thứ tự đảo ngược**, nên dùng thêm **INDEX** để gán từng hệ số cho đúng biến:
- $m_1 \rightarrow$ Num high school graduates
- $m_2 \rightarrow$ USA Economics
- ...
- $m_9 \rightarrow$ SAT cutoff
- $b \rightarrow$ intercept.
- Từ các hệ số, tạo công thức **dự đoán**:
- $\hat{Y} = m_1 X_1 + m_2 X_2 + \dots + m_9 X_9 + b$
- rồi tính $\hat{Y}$ cho từng năm và cho năm kế tiếp (dùng bộ X của năm đó).
- So sánh $\hat{Y}$ với Y thực tế (nếu có) để đánh giá sơ bộ độ hợp lý của mô hình.

Kết quả

	0,008022617053	12,76836133	-3,09130911	-3,4269548	-1,0429358	0,02891171384	-0,003520057857	1,394947044	0,033161	-67,058392		
Year	Num high school graduates	USA Economics	comparable	financial sch	financial aid	number of open ho	media advertisement inv	admission activities	SAT cutoff	Number of First Year Enrollment		
2004	25000	3	2	3	1	1100	13400	20	1000	200		
2005	25600	3	2	1	2	1005	12900	15	980	202		
2006	24367	3	3	2	3	900	8000	8	950	188		
2007	25500	3	2	2	3	980	8000	11	1020	209		
2008	28321	2	3	3	1	1212	7500	18	1000	232		
2009	28759	1	1	3	3	1220	10000	19	1010	220		
2010	25431	1	1	1	1	987	8000	10	950	188		
2011	24678	1	1	1	2	899	7500	8	1000	179		
2012	24987	2	2	2	3	1488	11000	7	1000	190		
2013	25100	2	3	2	3	900	11000	10	1000	175		
2014	25500	3	3	2	2	1130	9000	20	1000	220		
m1	9	dm1	0,00802261									
m2	8	dm2	12,7683613									
m3	7	dm3	-3,09130911									
m4	6	dm4	-3,4269548									
m5	5	dm5	-1,0429358									
m6	4	dm6	0,02891171									
m7	3	dm7	-0,00352005									
m8	2	dm8	1,39494704									
m9	1	dm9	0,03316125									
b	10	db	-67,058392									
b	10	db	-67,058392									
z	290741											

Nhận xét

- Các hệ số dương (Num high school graduates, USA Economics, open house visitors, admission activities, SAT cutoff...) cho thấy khi các yếu tố này tăng thì mô hình dự đoán số sinh viên nhập học tăng, phù hợp trực giác:
- Nhiều HS tốt nghiệp + kinh tế tốt → nhu cầu vào ĐH cao hơn.
- Nhiều hoạt động tuyển sinh, nhiều người đến tham quan → trường thu hút hơn.
- Các hệ số âm (comparable tuition fee, financial scholarship, financial aid, media advertisement investment) cho thấy trong bộ dữ liệu giả lập này, khi các giá trị đó tăng thì enrollment có xu hướng giảm; có thể do:
- Dữ liệu chỉ là fake data, số lượng mẫu ít (10 năm), nên tương quan có thể bị nhiễu.
- Một số biến có độ lớn hệ số nhỏ (ví dụ chi quảng cáo), tác động thực tế không đáng kể.
- Mô hình multiple linear regression cho phép kết hợp nhiều yếu tố cùng lúc để dự đoán enrollment, nhưng do dữ liệu ít và giả lập nên kết quả chủ yếu mang tính minh họa phương pháp, không dùng để ra quyết định thật trong thực tế.

Chương 6 bài 1

Link:

https://docs.google.com/spreadsheets/d/1FrSyBves2N3AiGHea_Y082KN4K4ubApY/edit?usp=drive_web&ouid=114344761387794005346&rtpof=true

Dữ liệu và mục tiêu

- Nguồn dữ liệu: bộ Heart Disease (đã chỉnh sửa cho phù hợp logistic regression) từ UCI Machine Learning Repository, gồm dữ liệu lâm sàng của bệnh nhân tim mạch.
- Biến đầu vào (predictors) – trong sheet bạn dùng là các cột:
 - age, sex, cp, trestbps, chol, fbs, restecg, thalach, exang, oldpeak, slope, ca, thal
 - (các cột này tương ứng với số thứ tự #3, #4, #9, #10,... như phần mô tả bên phải bảng).
- Biến đầu ra (target):
- Cột num (cột N) – chẩn đoán bệnh tim:
 - o 0: không bệnh / nguy cơ thấp
 - o 1: có bệnh / nguy cơ cao

Mục tiêu:

1. Dùng tập dữ liệu training ở phần trên bảng để xây dựng mô hình Logistic Regression dự đoán khả năng mắc bệnh tim.

2. Áp dụng mô hình này cho tập scoring ở cuối sheet để dự đoán num cho các bản ghi mới, sử dụng ngưỡng 0.5 ($=IF(P305 \leq 0.5, 0, 1)$).

Quy trình thực hiện

- **Chuẩn bị dữ liệu**
- Chọn vùng dữ liệu training:
 - o Y_range = cột num
 - o X_range = 13 cột đặc trưng (age → thal).
- Đảm bảo không có ô trống, tất cả dữ liệu numeric.
- **Khởi tạo bộ hệ số bằng LINEST**
- Dùng hàm:
 - o $=LINEST(num_range, X_range, TRUE, TRUE)$
-
- Dùng **INDEX** để lấy từng hệ số đúng thứ tự và gán cho:
 - o m1: age
 - o m2: sex
 - o ...
 - o m13: thal
 - o b: intercept.
- **Tính xác suất P(1) cho từng dòng training**
- Tạo cột $z = m1*age + m2*sex + \dots + m13*thal + b$ (dùng SUMPRODUCT).
- Tạo cột **P(1)**:
 - o $=1/(1+EXP(-z))$
-
- **Tạo nhãn dự đoán và hàm mất mát**
- Tạo cột **Outcome**:
 - o $=IF(P(1) \leq 0.5, 0, 1)$
-
- Tạo cột **Log Loss** từng mẫu:
 - o Nếu num=1 → $=-LN(P(1))$
 - o Nếu num=0 → $=-LN(1-P(1))$.
- Tính **tổng log loss** bằng SUM.
- **Tối ưu hệ số bằng Solver**
- Mở Solver:
 - o Set Objective: ô tổng log loss.
 - o To: **Min**.
 - o By Changing Variable Cells: dãy các hệ số m1...m13 và b.
 - o Solving Method: **GRG Nonlinear**.
- Run Solve và chọn **Keep Solver Solution**.
- **Áp dụng mô hình cho tập scoring**
- Dùng cùng bộ hệ số đã tối ưu: tính z, P(1) cho các bản ghi dưới cùng bảng.
- Dùng công thức:
 - o $=IF(P305 \leq 0.5, 0, 1)$
-
- (tổng quát: $=IF(P_row \leq 0.5, 0, 1)$) để ra **dự đoán num** 0 hoặc 1 cho từng bệnh nhân mới.

age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	num
63	1	1	145	233	1	2	150	0	2.3	3	0	6	0
67	1	4	160	286	0	2	108	1	1.5	2	3	3	1
67	1	4	120	229	0	2	129	1	2.6	2	2	7	1
37	1	3	130	250	0	0	187	0	3.5	3	0	3	0
41	0	2	130	204	0	2	172	0	1.4	1	0	3	0
56	1	2	120	236	0	0	178	0	0.8	1	0	3	0
62	0	4	140	268	0	2	160	0	3.6	3	2	3	1
57	0	4	120	354	0	0	163	1	0.6	1	0	3	0
63	1	4	130	254	0	2	147	0	1.4	2	1	7	1
53	1	4	140	203	1	2	155	1	3.1	3	0	7	1
57	1	4	140	192	0	0	148	0	0.4	2	0	6	0
56	0	2	140	294	0	2	153	0	1.3	2	0	3	0
56	1	3	130	256	1	2	142	1	0.6	2	1	6	1
44	1	2	120	263	0	0	173	0	0	1	0	7	0
52	1	3	172	199	1	0	162	0	0.5	1	0	7	0
57	1	3	150	168	0	0	174	0	1.6	1	0	3	0
48	1	2	110	229	0	0	168	0	1	3	0	7	1
54	1	4	140	239	0	0	160	0	1.2	1	0	3	0
48	0	3	130	275	0	0	139	0	0.2	1	0	3	0
49	1	2	130	266	0	0	171	0	0.6	1	0	3	0
64	1	1	110	211	0	2	144	1	1.8	2	0	3	0
58	0	1	150	283	1	2	162	0	1	1	0	3	0
58	1	2	120	284	0	2	160	0	1.8	2	0	3	1
58	1	3	132	224	0	2	173	0	3.2	1	2	7	1
60	1	4	130	206	0	2	132	1	2.4	2	2	7	1
50	0	3	120	219	0	0	158	0	1.6	2	0	3	0
58	0	3	120	340	0	0	172	0	0	1	0	3	0
66	0	1	150	226	0	0	114	0	2.6	3	0	3	0
43	1	4	150	247	0	0	171	0	1.5	1	0	3	0
40	1	4	110	167	0	2	114	1	2	2	0	7	1
69	0	1	140	239	0	0	151	0	1.8	1	2	3	0
60	1	4	117	230	1	0	160	1	1.4	1	2	7	1
64	1	3	140	335	0	0	158	0	0	1	0	3	1
59	1	4	135	234	0	0	161	0	0.5	2	0	7	0
44	1	3	130	233	0	0	179	1	0.4	1	0	3	0
42	1	4	140	226	0	0	178	0	0	1	0	3	0
43	1	4	120	177	0	2	120	1	2.5	2	0	7	1
57	1	4	150	276	0	2	112	1	0.6	2	1	6	1
55	1	4	132	353	0	0	132	1	1.2	2	1	7	1
61	1	3	150	243	1	0	137	1	1	2	0	3	0
65	0	4	150	225	0	2	114	0	1	2	3	7	1

273	64	1	1	170	227	0	2	155	0	0.6	2	0	7	0
274	66	0	3	146	278	0	2	152	0	0	2	1	3	0
275	39	0	3	138	220	0	0	152	0	0	2	0	3	0
276	57	1	2	154	232	0	2	164	0	0	1	1	3	1
277	58	0	4	130	197	0	0	131	0	0.6	2	0	3	0
278	57	1	4	110	335	0	0	143	1	3	2	1	7	1
279	47	1	3	130	253	0	0	179	0	0	1	0	3	0
280	55	0	4	128	205	0	1	130	1	2	2	1	7	1
281	35	1	2	122	192	0	0	174	0	0	1	0	3	0
282	61	1	4	148	203	0	0	161	0	0	1	1	7	1
283	58	1	4	114	318	0	1	140	0	4.4	3	3	6	1
284	58	0	4	170	225	1	2	146	1	2.8	2	2	6	1
285	56	1	2	130	221	0	2	163	0	0	1	0	7	0
286	56	1	2	120	240	0	0	169	0	0	3	0	3	0
287	67	1	3	152	212	0	2	150	0	0.8	2	0	7	1
288	55	0	2	132	342	0	0	166	0	1.2	1	0	3	0
289	44	1	4	120	169	0	0	144	1	2.8	3	0	6	1
290	63	1	4	140	187	0	2	144	1	4	1	2	7	1
291	63	0	4	124	197	0	0	136	1	0	2	0	3	1
292	41	1	2	120	157	0	0	182	0	0	1	0	3	0
293	59	1	4	164	176	1	2	90	0	1	2	2	6	1
294	57	0	4	140	241	0	0	123	1	0.2	2	0	7	1
295	45	1	1	110	264	0	0	132	0	1.2	2	0	7	1
296	68	1	4	144	193	1	0	141	0	3.4	2	2	7	1
297	57	1	4	130	131	0	0	115	1	1.2	2	1	7	1
298	57	0	2	130	236	0	2	174	0	0	2	1	3	1
299														
300	Scoring Dataset													
301	36	0	4	118	150	1	0	112	0	0.5	2	0	3	?
302	67	1	3	144	232	0	2	174	1	0	1	0	3	?

Nhận xét

- Mô hình logistic regression cho phép **biến cột num (0/1)** thành xác suất $P(co')$ nằm trong $[0,1]$, rất phù hợp với bài toán y tế – có thể xem như “nguy cơ mắc bệnh”.
- Các hệ số dương trong mô hình (tùy kết quả thực tế của nhóm) cho thấy **biến tăng** → **nguy cơ bệnh tim tăng**; các hệ số âm thì ngược lại (biến tăng → nguy cơ giảm). Ví dụ thường gặp trong y văn:
 - Tuổi (age), huyết áp nghỉ (trestbps), cholesterol (chol), ST depression (oldpeak) thường làm tăng nguy cơ.
 - Nhịp tim tối đa đạt được (thalach) cao hơn thường là dấu hiệu tốt hơn (hệ số có thể âm).
- Do dữ liệu có nhiều biến và không quá lớn, mô hình logistic regression là lựa chọn **đơn giản nhưng dễ giải thích**:
 - Bác sĩ hoặc người dùng có thể nhìn vào dấu và độ lớn hệ số để hiểu biến nào quan trọng.
 - Tuy nhiên, độ chính xác còn phụ thuộc vào:
 - Chất lượng dữ liệu (thiếu giá trị, nhiễu, phân phối không cân bằng giữa 0/1).
 - Việc chọn ngưỡng 0.5 – có thể chỉnh ngưỡng khác (vd. 0.4) để cân bằng giữa **số ca bỏ sót (false negative)** và **số ca báo động giả (false positive)** tùy mục tiêu y khoa.

Link :

<https://docs.google.com/spreadsheets/d/19PZqTI9CNY4ln5tLfHsVk8Uhb8JhOf1M/edit?gid=728222499#gid=72822249>

2

Bối cảnh chung

- **Dữ liệu:** bộ Heart Disease (UCI), các biến đầu vào:
age, sex, cp, trestbps, chol, fbs, restecg, thalach, exang, oldpeak, slope, ca, thal.
Đầu ra: num (0 = không bệnh, 1 = có bệnh).
- Bảng được chia làm hai phần:
- Training data: vùng A6:N219 (dùng để xây mô hình).
- Validation/Test data: vùng A224:N306 (dùng để kiểm tra mô hình).
- Mục tiêu chung của 2 sheet:
 1. Xây mô hình logistic regression trên tập training.
 2. Áp dụng mô hình cho tập validation để tính Cross-validation Accuracy.
 3. So sánh hai cách tối ưu:
 - Maximize log-likelihood.
 - Minimize log-loss.

Dữ liệu & mục tiêu

- Dữ liệu giống phần I.
- Mục tiêu riêng của sheet này:
 - o Dùng tập training để **ước lượng tham số** logistic regression bằng cách **tối đa hóa tổng log-likelihood** (ô “To-maximize” ở góc trên).
 - o Sau đó kiểm tra mô hình trên tập validation và tính **Cross-validation Diff** (số dòng dự đoán sai) và **Cross-validation Accuracy** (tỉ lệ dự đoán đúng).

Quy trình thực hiện

Trên tập training (A6:N219)

1. Dùng LINEST để tạo **bộ hệ số ban đầu** M1...M13 và b (hàng 1-2).
2. Với mỗi dòng dữ liệu:
 - Tính $z = m1age + \dots + m13thal + b$ (cột $m1x1 + m2x2 + \dots + b$).
 - Tính xác suất $P(1) = 1 / (1 + EXP(-z))$.
 - Tạo cột **Likelihood**: nếu num=1 $\rightarrow$ Likelihood = P(1); nếu num=0 $\rightarrow$ Likelihood = 1-P(1).
 - Tạo cột **Ln(Likelihood)** = LN(Likelihood) (nếu Likelihood=0 thì thay bằng một số âm rất lớn).
 1. Ô “To-maximize” là **tổng Ln(Likelihood)** trên toàn bộ training set.
 2. Dùng **Solver**:
 - Set Objective = ô “To-maximize”, chọn **Max**.
 - By Changing Variable Cells = dãy hệ số M1...M13 và b.
 - Method = **GRG Nonlinear** $\rightarrow$ Solve $\rightarrow$ Keep Solver Solution. $\rightarrow$ Thu được bộ hệ số logistic regression tối ưu theo log-likelihood.

Áp dụng cho tập validation (A224:N306)

1. Dùng chính bộ hệ số đã tối ưu để:
 - Tính z, P(1) cho từng dòng validation.
 - Tạo **Predicted Outcome**: =IF(P(1)<=0.5,0,1).
 - Tính **Difference**: 0 nếu dự đoán đúng, 1 nếu sai.
1. **Cross-validation Diff** = tổng Difference (số mẫu sai).

→ ~ **50.6%** theo file của bạn.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y
1		13	12	11	10	9	8	7	6	5	4	3	2	1	14										
2	M1	M2	M3	M4	M5	M6	M7	M8	M9	M10	M11	M12	M13	b					To-Minimize	131,8468581					
3	-0,00105	0,1121	0,1032	0,00239	0,0001	-0,06	0,0215	-0,0026	0,124	0,03178	0,086	0,156	0,0525	-0,4123069595											
4	-0,00105	0,1121	0,1032	0,00239	0,0001	-0,06	0,0215	-0,0026	0,124	0,03178	0,086	0,156	0,0525	-0,4123069595											
5	age	sex	cp	trestbps	chol	fb	restecg	thalach	exang	oldpeak	slope	ca	thal	num	m1x1+m2x2+...+ P(1)				41						
6	67	1	4	160	286	0	2	108	1	1,5	2	3	3	1	1,18898958	0,7665603167		1	0	0,766560316	0,2658418927				
7	57	0	4	120	354	0	0	163	1	0,6	1	0	3	0	0,2243576866	0,5585853218		1	0,444144678	0,8116049178					
8	56	0	2	140	294	0	2	153	0	1,3	2	0	3	0	0,1143437816	0,5285525978		1	0,471447402	0,7519477374					
9	49	1	2	130	266	0	0	171	0	0,6	1	0	3	0	0,006837237496	0,5017093027		1	0,498290697	0,6965716426					
10	64	1	1	110	211	0	2	144	1	1,8	2	0	3	0	0,197944744	0,5493525355		1	0,450674764	0,7970093426					
11	42	1	4	140	226	0	0	178	0	0	1	0	3	0	0,2026316611	0,5504852913		1	0,449514708	0,7995867032					
12	55	1	4	132	353	0	0	132	1	1,2	2	1	7	1	0,9223545874	0,7155216261		1	0,715521626	0,3347434553					
13	61	1	3	150	243	1	0	137	1	1	2	0	3	0	0,3891230654	0,5960715773		1	0,403928422	0,9065175883					
14	71	0	2	160	302	0	0	162	0	0,4	1	2	3	0	0,2784632283	0,5691694237		1	0,430830576	0,8420403606					
15	61	0	4	130	330	0	2	169	0	0	1	0	3	1	0,125059208	0,5312220539		1	0,531222053	0,6325751645					
16	50	1	4	150	243	0	2	128	0	2,6	2	0	7	1	0,7753173593	0,6846700213		1	0,684670021	0,3788182776					
17	44	1	2	130	219	0	2	188	0	0	1	0	3	0	-0,01409517667	0,4964762642		0	0,503523735	0,6861244263					
18	51	0	4	130	305	0	0	142	1	1,2	2	0	7	1	0,6209265268	0,6504292433		0	0,650429243	0,4301227596					
19	58	0	4	128	216	0	2	131	1	2,2	2	3	7	1	1,285506689	0,7833856786		1	0,783385678	0,244130139					
20	54	1	4	120	188	0	0	113	0	1,4	2	1	7	1	0,8083394356	0,6917555352		1	0,691755535	0,3685226585					
21	59	1	4	170	326	0	2	140	1	3,4	3	0	7	1	1,028159387	0,736558899		1	0,736558899	0,3057660745					
22	65	0	3	155	269	0	0	148	0	0,8	1	0	3	0	0,1085325331	0,5271065305		1	0,472893469	0,7488851388					
23	65	1	4	110	248	0	2	158	0	0,6	1	2	6	1	0,6954041339	0,6671680231		1	0,667168023	0,4047133562					
24	60	1	4	125	258	0	2	141	1	2,8	2	1	7	1	0,9598659474	0,7230949648		1	0,723094964	0,3242147172					
25	44	0	3	108	141	0	0	175	0	0,6	2	0	3	0	0,01285568514	0,503213877		1	0,496786123	0,6995956816					
26	52	1	4	128	255	0	0	161	1	0	1	1	7	1	0,7031162692	0,6688783267		1	0,668878326	0,4021531086					
27	61	1	4	120	260	0	0	140	1	3,6	2	1	7	1	0,9320017463	0,7174812199		1	0,717481219	0,3320085061					
28	39	1	4	118	219	0	0	140	0	1,2	2	0	7	1	0,5881578806	0,6429423664		1	0,642942366	0,4417001911					
29	52	1	1	118	186	0	2	190	0	0	2	0	6	0	0,08102940759	0,5202462754		1	0,479753724	0,7344823805					
30	62	0	3	130	263	0	0	97	0	1,2	2	1	7	1	0,65279084	0,6576390962		1	0,657639096	0,4190989841					
31	48	1	4	130	256	1	2	150	1	0	1	2	7	1	0,8734214385	0,7054571291		1	0,705457129	0,3489092762					
32	65	1	1	138	282	1	2	174	0	1,4	2	1	3	1	0,1441483402	0,535974814		1	0,535974814	0,6236681078					
33	45	0	2	130	234	0	2	175	0	0,6	2	0	3	0	0,01476462625	0,5036910895		1	0,496308910	0,7005567427					
34	29	1	2	130	204	0	2	202	0	0	1	0	3	0	-0,0370371809	0,4907431283		0	0,509256871	0,6748027302					
35	51	1	4	140	261	0	2	186	1	0	1	0	3	0	0,343554561	0,5850537091		1	0,414946290	0,8796061866					
36	55	0	2	135	250	0	2	161	0	1,4	2	0	3	0	0,08049054453	0,5201117791		1	0,479888220	0,7342020753					
37	70	1	4	145	174	0	0	125	1	2,6	3	0	7	1	0,9108367203	0,7131713511		1	0,713171351	0,3380335633					
38	51	1	3	125	245	1	2	166	0	2,4	2	0	3	0	0,2263128188	0,5563379523		1	0,443662047	0,8126921603					
39	59	1	2	140	221	0	0	164	1	0	1	0	3	0	0,1392259127	0,5347503633		1	0,465249636	0,7651811644					
40	59	1	1	170	288	0	2	159	0	0,2	2	0	7	1	0,3505970191	0,586762347		1	0,586762347	0,5331354014					
41	52	1	2	128	205	1	0	184	0	0	1	0	3	0	-0,1293158038	0,4677160258		0	0,532283974	0,6305781455					
42	41	1	3	112	250	0	0	179	0	0	1	0	3	0	0,03337456638	0,5083428672		1	0,4916571321	0,70997369					
43	52	1	1	152	298	1	0	178	0	1,2	2	0	7	0	0,1864303457	0,5464730618		1	0,453526938	0,7907006105					
44	64	1	4	120	246	0	2	96	1	2,2	3	1	3	1	0,9191781008	0,7148746085		1	0,714874608	0,3356481244					
45	51	1	4	140	299	0	0	173	1	1,6	1	0	7	1	0,6001066351	0,6456807023		0	0,645680702	0,4374501663					
46	54	0	3	110	214	0	0	158	0	1,6	2	0	3	0	0,09706676585	0,523000477		1	0,476999552	0,7407397757					

- Mô hình logistic regression được huấn luyện bằng **max log-likelihood** cho kết quả:

- o Cross-validation Diff = 41 mẫu sai.
- o Cross-validation Accuracy $\approx 50.6\%$, chỉ nhỉnh hơn đoán ngẫu nhiên một chút.
- Điều này cho thấy:
 - o Bộ đặc trưng + mô hình tuyến tính hiện tại **phân tách hai lớp chưa tốt** trên tập kiểm tra.
 - o Đây là ví dụ tốt để hiểu **cross-validation**: mô hình có thể khớp tạm ổn trên training nhưng khi mang sang validation thì độ chính xác không cao.
- Ý nghĩa bài tập: không phải để có mô hình “xịn”, mà để sinh viên **nắm quy trình**:
 1. Chia dữ liệu train/validation.
 2. Huấn luyện logistic regression (max log-likelihood).
 3. Đánh giá bằng cross-validation accuracy.

Sheet “LR-log-loss”

Link :

<https://docs.google.com/spreadsheets/d/19PZqTI9CNY4ln5tLfHsVk8Uhb8JhOf1M/edit?gid=362748354#gid=362748354>

Dữ liệu & mục tiêu

- Dữ liệu: vẫn là Heart Disease, train A6:N219, validation A224:N306.
- Mục tiêu riêng:
 - o Thay vì tối đa hóa log-likelihood, ta **tối thiểu hóa tổng log-loss** (ô “To-Minimize”).
 - o Sau đó lại kiểm tra trên validation để so sánh kết quả với sheet “LR-log-likelihoods”.

Quy trình

1. Dùng bộ hệ số ban đầu từ LINEST, tính:
 - $z, P(1)$ cho từng dòng training.
 - **Log-loss** từng mẫu:
 - Nếu $num=1 \rightarrow -\ln(P(1))$
 - Nếu $num=0 \rightarrow -\ln(1-P(1))$.
1. Ô “To-Minimize” = **tổng log-loss**.
2. Dùng Solver:
 - Set Objective = ô “To-Minimize”, chọn **Min**.
 - Changing Variable Cells = các hệ số M1...M13 và b.
 - Method = GRG Nonlinear $\rightarrow$ Solve $\rightarrow$ Keep Solver Solution.
1. Áp dụng bộ hệ số đã tối ưu cho tập validation giống hệt bước ở sheet trước:
 - Tính $z, P(1)$, Predicted Outcome, Difference.
 - Tính Cross-validation Diff và Accuracy.

Validation/Test Dataset													Actual Outcome	m1x1+m2x2+...+ P(1)	Predicted Outcome	Difference	
63	1	1	145	233	1	2	150	0	2,3	3	0	6	0	0,337435926	0,5835675446	1	1
67	1	4	120	229	0	2	129	1	2,6	2	2	7	1	1,119502787	0,7538964768	1	0
37	1	3	130	250	0	0	187	0	3,5	3	0	3	0	0,3446622808	0,5853226003	1	1
41	0	2	130	204	0	2	172	0	1,4	1	0	3	0	-0,03793639196	0,4905170393	0	0
53	1	4	140	203	1	2	155	1	3,1	3	0	7	1	0,8317253404	0,6967196203	1	0
57	1	4	140	192	0	0	148	0	0,4	2	0	6	0	0,5197233903	0,6270830834	1	1
56	1	3	130	256	1	2	142	1	0,6	2	1	6	1	0,6795529176	0,6636389059	1	0
52	1	3	172	199	1	0	162	0	0,5	1	0	7	0	0,3629886079	0,5897636987	1	1
48	1	2	110	229	0	0	168	0	1	3	0	7	1	0,360533422	0,5891695543	1	0
60	1	4	130	206	0	2	132	1	2,4	2	2	7	1	1,133963441	0,7565695963	1	0
50	0	3	120	219	0	0	158	0	1,6	2	0	3	0	0,1207964363	0,530162441	1	1
43	1	4	150	247	0	0	171	0	1,5	1	0	3	0	0,2940970987	0,5729988733	1	1
69	0	1	140	239	0	0	151	0	1,8	1	2	3	0	0,1959749988	0,5488375443	1	1
43	1	4	120	177	0	2	120	1	2,5	2	0	7	1	0,8459916976	0,6997256342	1	0
59	1	3	150	212	1	0	157	0	1,6	1	0	3	0	0,1424096956	0,535542376	1	1
58	1	3	112	230	0	2	165	0	2,5	2	1	7	1	0,6268118166	0,6517662003	1	0
53	1	3	130	197	1	2	152	0	1,2	3	0	3	0	0,3166741618	0,5785135067	1	1
44	1	4	112	290	0	2	153	0	0	1	1	3	1	0,4067456453	0,6003072895	1	0
51	1	1	125	213	0	2	125	1	1,4	1	1	3	0	0,3552724436	0,5878955462	1	1
46	0	3	142	177	0	2	160	1	1,4	3	0	3	0	0,4159781848	0,6025204654	1	1
54	0	3	135	304	1	0	170	0	0	1	0	3	0	-0,07544347471	0,4811480721	0	0
62	1	4	120	267	0	0	99	1	1,8	2	2	7	1	1,139881456	0,7576578735	1	0
44	1	4	110	197	0	2	177	0	0	1	1	3	1	0,3280168452	0,5812767666	1	0
65	0	3	160	360	0	2	151	0	0,8	1	0	3	0	0,1658740867	0,5413737014	1	1
68	1	3	180	274	1	2	150	1	1,6	2	0	7	1	0,6950267	0,6670842067	1	0
53	0	4	138	234	0	2	160	0	0	1	0	3	0	0,1657432378	0,541341213	1	1
63	0	3	135	252	0	2	172	0	0	1	0	3	0	0,01498984042	0,5037473899	1	1
48	1	4	122	222	0	2	186	0	0	1	0	3	0	0,1746955512	0,5435631538	1	1
45	1	4	115	260	0	2	185	0	0	1	0	3	0	0,1679830083	0,5418972759	1	1
57	0	4	128	303	0	2	159	0	0	1	1	3	0	0,304751976	0,5756037639	1	1
43	0	4	132	341	1	2	136	1	3	2	0	7	1	0,6865213709	0,6651926421	1	0
35	0	4	138	183	0	0	182	0	1,4	1	0	3	0	0,1221326723	0,5304952709	1	1
63	0	4	150	407	0	2	154	0	4	2	3	7	1	1,113882928	0,7528523003	1	0
62	0	4	124	209	0	0	163	0	0	1	0	3	0	0,06884946364	0,5172055699	1	1
43	0	3	122	213	0	0	165	0	0,2	2	0	3	0	0,06925598987	0,5173070804	1	1
47	1	3	108	243	0	0	152	0	0	1	0	3	1	0,08817229705	0,5220288045	1	0
55	1	4	160	289	0	2	145	1	0,8	2	1	7	1	0,9782772554	0,7267662524	1	0

Nhận xét

- Kết quả cross-validation của sheet **LR-log-loss** gần như **trùng với sheet LR-log-likelihoods**:
 - o Diff ≈ 41, Accuracy ≈ 50.6%.
- Điều này minh họa rằng:
 - o **Maximize tổng log-likelihood** và **minimize tổng log-loss** thực chất là **hai cách viết khác nhau của cùng một tiêu chí tối ưu**, nên cho bộ hệ số (và độ chính xác) giống nhau.
- Về mặt phương pháp:
 - o Trong machine learning hiện đại, người ta thường dùng **log-loss** (cross-entropy) làm loss function;
 - o Bài này cho thấy log-loss xuất phát trực tiếp từ khái niệm likelihood trong thống kê.

6. Kết luận

Qua quá trình thực hành, nhóm rút ra một số điểm:

Linear Regression

- o Dễ hiểu, trực quan qua đồ thị đường thẳng.
- o Có công thức đóng để tính nhanh m, b.
- o Tuy nhiên, dễ bị ảnh hưởng bởi outlier và chỉ phù hợp khi mối quan hệ gần tuyến tính.

Logistic Regression

- o Thễ hiện rõ ý nghĩa xác suất, phù hợp cho bài toán phân loại nhị phân.
- o Khái niệm **odds**, **log-odds**, **likelihood**, **log loss** giúp sinh viên hiểu sâu hơn về tư duy xác suất trong học máy.

- o Không có công thức đóng đơn giản, nên thường phải tối ưu bằng các thuật toán số (Solver, gradient descent).

Gradient Descent vs. Excel / Solver

- o Excel + Solver cung cấp cách “thực nghiệm” trực quan: thay đổi hệ số $\rightarrow$ thấy số mẫu sai, log loss thay đổi.
- o Gradient Descent cho cái nhìn ở góc độ **thuật toán ML hiện đại**, giúp kết nối môn học với việc lập trình Python sau này.
- o Về bản chất, cả Solver và Gradient Descent đều là các phương pháp tối ưu để tìm bộ tham số tốt nhất cho cùng một hàm mất mát.

Kĩ năng Excel

- o Các hàm như **LINEST**, **INDEX**, **SUMPRODUCT**, **EXP**, **LN**, **IF** là nền tảng quan trọng để triển khai mô hình trong Excel.
- o Việc triển khai bước-bước trong Excel giúp sinh viên không chỉ “bấm hàm” mà còn thấy rõ từng phép toán phía sau mô hình.